

UNIVERSITÀ CATTOLICA DEL SACRO CUORE

SEDE DI MILANO

Facoltà di Scienze Bancarie, Finanziarie e Assicurative

Corso di Laurea in Economia dei Mercati e degli Intermediari Finanziari

MACHINE LEARNING APPLICATO AGLI
INVESTIMENTI BASATI SU FACTORS IN
OBBLIGAZIONI SOCIETARIE



Relatore:

Prof. Sergio Guido Trezzi

Collaboratori:

Francesco Mercatelli

Pierfrancesco Dionigi

Candidato:

Luca Manca

Matricola: 5206124

Anno Accademico 2024/2025

Indice

1	Introduzione	4
1.1	Research Question e obiettivi della tesi	4
2	Il Mercato Obbligazionario Corporate	6
2.1	Fixed Income contro Equity	6
2.2	Il Mercato Europeo e le sue Implicazioni	7
3	Factor Investing	9
3.1	Definizione e contesto storico	9
3.2	I Factor nel Fixed Income	9
3.3	Gli OLS non bastano	10
4	Machine Learning	11
4.1	Il Deep Learning nelle Serie Temporalì	11
4.2	Architettura di un modello LSTM	12
4.3	Training, Struttura a Layer e Hyperparameter Tuning	13
4.4	Applicazione del Modello: Trading Long-Short	14
4.5	Metriche di Performance	15
5	Bias e Limitazioni del Machine Learning sul Factor Investing	17
5.1	Bias nella ricerca sui fattori	17
5.2	Requisiti dei Dati per il Machine Learning nel Credito	18
5.3	Overfitting e Tecniche di Regularizzazione	19
6	Dati	21
6.1	Fonti Dati e Universo Investibile	21
6.2	Preprocessing dei Dati Grezzi	22
6.3	Matching Bond-Finanziari: Algoritmo Tri-Livello	23
6.4	Dati Derivati: Prospetti, Metriche e Factors	23
6.5	Le Assunzioni	27
6.6	Limiti dei Dati e Mancanze del Campione	28
6.7	Considerazioni sul Dataset finale	30
6.8	Gestione dei Valori Mancanti e Rimozione NaN Iniziali	31
7	Features Selection & Preprocessing	32
7.1	Filtri di Qualità sul Dataset	32
7.2	Features Selection: Approccio Theory-Driven	32
7.3	Definizione del Target Predittivo	34
7.4	Normalizzazione	35
7.5	Split Temporale e Validazione	35
8	Implementazione del Modello	37
8.0.1	Costruzione delle Sequenze	37
8.1	Architettura del Modello LSTM	37

8.2	Loss Function e Ottimizzatore	38
8.3	Procedura di Training	39
8.4	Riepilogo Configurazione	41
8.5	Strategia di Trading Long-Short	41
9	Risultati e Discussione	44
9.1	Performance Predittiva Out-of-Sample	44
9.2	Performance della Strategia Long-Short	46
9.3	Confronto con Benchmark	47
9.4	Discussione e Interpretazione	48
10	Conclusioni	49
10.1	Limitazioni e Cautele	49
10.2	Prospettive Future	49
10.3	Riproducibilità e Materiali Supplementari	50
10.4	Conclusione Finale	50
	Bibliografia	51

1 Introduzione

Il mercato obbligazionario corporate rappresenta una delle asset class più rilevanti per gli investitori istituzionali a livello globale. Fondi pensione, compagnie assicurative e gestori patrimoniali allocano porzioni predominanti del proprio capitale in obbligazioni societarie: la natura contrattuale dei flussi cedolari e la priorità in caso di insolvenza rendono il fixed income particolarmente adatto a soddisfare le esigenze di stabilità richieste dalla maggior parte dei clienti istituzionali (fondi pensione con obblighi verso beneficiari, assicurazioni con riserve tecniche da fronteggiare). A questo si aggiunge il framework regolamentare che favorisce allocazioni verso strumenti a reddito fisso rispetto all'equity, più volatile per definizione. Tuttavia, il contesto macroeconomico degli ultimi due decenni ha profondamente modificato le dinamiche di questo mercato.

Il periodo di Quantitative Easing (2014-2022) e la successiva normalizzazione dei tassi (2022-2024) hanno drasticamente aumentato la volatilità e i rischi di duration nei portafogli obbligazionari, rendendo le strategie di gestione attiva essenziali per generare rendimenti reali positivi.

In questo contesto, le strategie di gestione attiva hanno acquisito rinnovata centralità. A differenza dei mercati azionari, dove la replica passiva di indici è efficiente e liquida, il mercato obbligazionario corporate presenta sfide strutturali: frammentazione degli emittenti, illiquidità relativa e costi di transazione elevati rendono la replica fisica degli indici complessa e costosa. Di conseguenza, la capacità di selezionare singoli bond superiori (*Bond Picking*) diventa fondamentale per generare alpha, definito come extra-rendimento rispetto al benchmark di riferimento.

Nelle strategie quantitative, i metodi tradizionali - come le regressioni OLS - presentano limiti strutturali nella modellazione degli spread per l'intrinseca non-linearità delle relazioni finanziarie e il condizionamento dello stato del mercato interessato [1]. Il Deep Learning offre strumenti in grado di catturare queste complessità senza imporre forme funzionali rigide (Sezione 3.3).

1.1 Research Question e obiettivi della tesi

La presente tesi si propone di rispondere alla seguente domanda di ricerca:

È possibile costruire una strategia di investimento sistematica basata su Factor Investing nel mercato obbligazionario corporate europeo che generi extra-rendimenti significativi attraverso l'applicazione di tecniche di Deep Learning?

Per rispondere a tale quesito, il lavoro si articola nei seguenti obiettivi specifici:

1. **Costruzione di un dataset proprietario integrato:** combinare dati di mercato (prezzi obbligazionari, spread, duration) e dati fondamentali (bilanci aziendali, metriche finanziarie) per il mercato corporate europeo, superando i limiti di disponibilità e frammentazione tipici di questo universo investibile.
2. **Implementazione di un modello LSTM (Long Short-Term Memory):** sviluppare e addestrare una rete neurale ricorrente progettata specificamente per l'analisi di serie temporali finanziarie, in grado di catturare dipendenze temporali complesse negli spread di credito.

3. **Validazione empirica tramite strategie Long-Short:** costruire portafogli Long-Short basati sui segnali predittivi del modello e valutarne la performance attraverso metriche di rischio-rendimento standard, confrontando i risultati con benchmark tradizionali.
4. **Analisi critica dei limiti metodologici:** identificare e discutere le principali sfide operative dell'approccio proposto, con particolare attenzione alla qualità e disponibilità dei dati, all'illiquidità del mercato e ai rischi di overfitting.

L'analisi si concentra sul mercato corporate europeo per 2 motivi principali: (i) tale universo rappresenta il naturale mercato di investimento per gli investitori istituzionali europei (quota predominante degli attori finanziari provenienti dai Paesi europei), che riducono drasticamente il rischio di cambio e conseguenti costi di copertura valutaria, (ii) per colmare il gap accademico: la letteratura su Factor Investing e ML nel Fixed Income si è storicamente concentrata sugli USA, dove viene assicurata disponibilità di dati granulari e standardizzati, rendendo il contesto europeo significativamente meno studiato 2.2.

2 Il Mercato Obbligazionario Corporate

Il mercato obbligazionario corporate costituisce un segmento fondamentale dei mercati finanziari globali, caratterizzato da dinamiche strutturali che lo distinguono nettamente dal mercato azionario. Comprendere tali peculiarità è essenziale per sviluppare strategie quantitative efficaci.

2.1 Fixed Income contro Equity

Le obbligazioni societarie sono contratti di debito attraverso i quali l'emittente si impegna a corrispondere flussi di cassa predeterminati: cedole periodiche e rimborso del capitale a scadenza. A differenza delle azioni, che conferiscono diritti residuali sugli utili e sull'attivo societario, le obbligazioni corporate presentano tre caratteristiche distintive rilevanti per l'analisi quantitativa:

- **Flussi di cassa contrattualmente definiti:** cedole e rimborso del capitale sono stabiliti all'emissione, rendendo le obbligazioni principalmente sensibili a due fattori di rischio: le variazioni dei tassi di interesse privi di rischio e il deterioramento del merito creditizio dell'emittente. Questa prevedibilità contrattuale distingue il fixed income dall'equity, dove i dividendi e i flussi di cassa futuri dipendono dalle performance operative dell'azienda.
- **Priorità in caso di insolvenza:** gli obbligazionisti godono di precedenza rispetto agli azionisti nella distribuzione dell'attivo fallimentare. Tale caratteristica genera un profilo di rischio-rendimento asimmetrico: i rendimenti sono limitati verso l'alto dal tasso cedolare contrattuale (cap), mentre le perdite significative si materializzano solo in caso di default. Gli azionisti, in quanto detentori di claim residuali, sopportano perdite totali ben prima degli obbligazionisti.
- **Scadenza finita:** a differenza delle azioni che rappresentano strumenti perpetui, le obbligazioni hanno una vita residua che influenza direttamente la sensibilità ai tassi di interesse (duration) e determina un fenomeno noto come *pull-to-par*: man mano che la scadenza si avvicina, il prezzo dell'obbligazione converge verso il valore nominale, indipendentemente dalle fluttuazioni precedenti, assumendo assenza di default.

Implicazioni per le strategie quantitative

Queste differenze strutturali hanno profonde implicazioni per l'applicazione di tecniche di Machine Learning. Il mercato azionario è caratterizzato da elevata volatilità intrinseca (sensibilità a news, sentiment, trading ad alta frequenza) e abbondanza di dati standardizzati (CRSP, Compustat, Yahoo Finance). Questa combinazione ha alimentato una vasta letteratura accademica e la proliferazione di hedge fund quantitativi che hanno progressivamente arbitrato le inefficienze di pricing, rendendo sempre più difficile generare alpha sistematico.

Il mercato obbligazionario corporate presenta dinamiche opposte: la minore volatilità dei prezzi (flussi contrattualmente definiti, pull-to-par), la scarsa disponibilità di dati consolidati e la complessità del trading OTC hanno storicamente limitato l'applicazione di ML. Paradossalmente, queste barriere all'ingresso – che nel mercato europeo sono ancora più marcate rispetto al contesto statunitense – potrebbero preservare inefficienze di pricing sfruttabili.

La scarsità di applicazioni sistematiche di ML nel Fixed Income europeo rappresenta quindi un'opportunità per chi dispone degli strumenti analitici adeguati.

Le componenti dello spread creditizio

Elemento centrale nella valutazione delle obbligazioni corporate è il concetto di **credit spread**, ovvero il differenziale di rendimento rispetto a un titolo privo di rischio di pari scadenza. La letteratura accademica ha identificato quattro componenti principali che determinano lo spread osservato sul mercato:

- **Perdita attesa per default:** compenso per il rischio di insolvenza dell'emittente, funzione della probabilità di default e del recovery rate.
- **Premio per il rischio di credito:** compenso per il rischio sistematico, non diversificabile, associato agli eventi creditizi. I default tendono a concentrarsi durante recessioni, quando l'utilità marginale della ricchezza è elevata.
- **Premio per liquidità:** molte obbligazioni corporate sono negoziate con frequenza limitata, rendendo difficile la liquidazione in tempi brevi. Gli investitori, quindi, richiedono uno spread aggiuntivo per detenere titoli illiquidi con costi di liquidazione elevati.
- **Altri fattori non-credit:** differenze fiscali, jump risk (rischio di variazioni improvvise della qualità creditizia) ed effetti regolamentari.

Microstruttura di mercato e implicazioni operative

Il mercato obbligazionario corporate differisce strutturalmente da quello azionario per la sua natura **Over-The-Counter (OTC)** [2]. Le transazioni non avvengono solamente su borse centralizzate, bensì principalmente attraverso negoziazioni bilaterali tra investitori e dealer. Questa architettura genera due conseguenze:

- **Opacità dei prezzi:** non esiste un "prezzo unico" osservabile. Si utilizzano prezzi indicativi o medie di quotazioni dealer, che potrebbero non essere eseguibili (Assunzione 6.5, Capitolo 6).
- **Illiquidità e costi elevati:** molti titoli non sono scambiati per giorni o settimane. I costi di transazione, rappresentati dallo spread bid ask, e i ritardi di esecuzione possono rendere non implementabili strategie profittevoli su carta (discusso nel Capitolo 9).

2.2 Il Mercato Europeo e le sue Implicazioni

Nonostante tali sfide, il mercato europeo mantiene rilevanza per investitori istituzionali del continente, evitando il rischio di cambio implicito nell'investimento in dollari.

Il mercato obbligazionario corporate europeo differisce da quello statunitense lungo due dimensioni principali.

Primo, la **frammentazione giurisdizionale**: il mercato europeo si estende su diverse giurisdizioni con sistemi legali, fiscali e regolamentari distinti, introducendo una componente di "rischio paese" assente nel mercato USA. Questa frammentazione complica la definizione del **tasso privo di rischio**. Mentre negli USA il Treasury yield è un benchmark univoco, in Europa coesistono multiple curve governative (Bund, OAT, BTP, Bonos). Nel presente lavoro si utilizza la curva AAA Euro Area (BCE) [3] come unico riferimento risk-free (Assunzione 6.5, Capitolo 6). Tale scelta garantisce comparabilità cross-country, ma per emittenti di paesi periferici lo spread incorporerà implicitamente anche il sovereign spread.

Secondo, minore **trasparenza e disponibilità di dati**. Negli USA, il sistema TRACE impone pubblicazione obbligatoria delle transazioni. In Europa, MiFID II (2018) ha intro-

dotto solo recentemente requisiti simili con limitazioni significative, riducendo l'accessibilità dei dati consolidati. Questa asimmetria informativa ha storicamente limitato la ricerca accademica sul mercato europeo.

Nonostante tali sfide, il mercato europeo mantiene rilevanza per investitori istituzionali del continente, evitando il rischio di cambio implicito nell'investimento in dollari e quindi riducendo i costi di hedging.

3 Factor Investing

Il Factor Investing rappresenta un ponte concettuale tra l'analisi fondamentale tradizionale e le strategie quantitative moderne.

3.1 Definizione e contesto storico

Il **Factor Investing** è un approccio alla gestione di portafoglio che seleziona titoli sulla base della loro esposizione a *fattori di rischio sistematici* che storicamente generano rendimenti superiori al mercato. L'intuizione fondamentale è che non tutti i rischi sono remunerati allo stesso modo: alcuni fattori offrono premi persistenti nel tempo, sfruttabili attraverso strategie disciplinate e replicabili.

Questo paradigma nasce nel mercato azionario come evoluzione del Capital Asset Pricing Model (CAPM). I lavori seminali di Fama e French [4], [5] hanno dimostrato che i rendimenti azionari non sono spiegati esclusivamente dal rischio di mercato (Beta), ma dall'esposizione a specifici fattori che catturano dimensioni di rischio sistematico premiate dagli investitori nel lungo periodo.

3.2 I Factor nel Fixed Income

Negli ultimi due decenni, l'approccio factor-based è stato trasposto con successo al mercato obbligazionario corporate. Studi empirici [6], [7], [8] hanno documentato che anomalie di prezzo analoghe a quelle osservate nell'equity persistono anche nel credito, generando alpha significativi. Tuttavia, l'applicazione del Factor Investing al Fixed Income presenta sfide uniche rispetto al mercato azionario: la multidimensionalità del rischio (tasso di interesse e credito simultaneamente), l'illiquidità relativa e, soprattutto, la scarsità di dati storici granulari rispetto all'equity limitano la replicabilità degli approcci sviluppati per le azioni.

La letteratura accademica sul Fixed Income Factor Investing identifica quattro fattori "core" nel mercato del credito corporate, ciascuno dei quali cattura una dimensione specifica di rischio-rendimento.

- **Size:** Emittenti più piccoli sovraperformano i grandi a parità di credito, compensando la minore liquidità, una copertura analitica inferiore e una maggiore sensibilità a shock idiosincratici.
- **Value:** Identifica bond con spread di mercato superiore al "Fair Value" stimato utilizzando rating, settore, leverage e probabilità di default implicita. Sfruttando mean-reversion da sovra-reazioni temporanee del mercato a notizie negative.
- **Momentum:** I titoli con spread in restringimento tendono a continuare il trend nel breve-medio periodo; ciò è spesso spiegato da 2 meccanismi: under-reaction degli investitori ad informazioni pubbliche e il comportamento di investitori istituzionali, che concentrano progressivamente i loro flussi di capitale su emittenti in miglioramento.
- **Defensive/Quality:** Empiricamente, emittenti più sicuri - con alta qualità creditizia, basso leverage, alta profitabilità - generano rendimenti aggiustati per il rischio superiori ai titoli High Yield, in quanto proteggono da stress sistemici e beneficiano del "Lottery Ticket Effect" [9], per cui parte degli investitori sono attratti da titoli ad alto rischio e rendimento, comprimendone il rapporto rischio rendimento.

3.3 Gli OLS non bastano

Le tecniche econometriche tradizionali, in particolare le regressioni lineari OLS (Ordinary Least Squares), costituiscono lo strumento standard per la modellazione dei rendimenti finanziari. Tuttavia, tali approcci si fondano su due assunzioni restrittive che risultano sistematicamente violate nei mercati obbligazionari corporate.

La prima assunzione è che la relazione tra variabili sia **lineare e additiva**. Questa ipotesi risulta inadeguata, ad esempio: l'effetto combinato di alta leva e basso rating non è semplicemente la somma degli effetti individuali. Un emittente con leverage moderato e rating BBB può essere relativamente sicuro, mentre un emittente con leverage elevato e rating BB può trovarsi in una zona di rischio esponenzialmente superiore, data la prossimità alla soglia di default. Tali interazioni non lineari tra fattori di rischio richiedono forme funzionali flessibili che i modelli lineari non possono rappresentare.

La seconda assunzione è che la relazione tra variabili indipendenti (ad esempio, leva finanziaria, rating, spread) e variabile dipendente (rendimento futuro o variazione di spread) sia **stabile nel tempo**. Nel credito, questa ipotesi è empiricamente falsa: l'impatto della leva finanziaria sullo spread può essere trascurabile in periodi di espansione economica, quando l'accesso al credito è facile e i default rari, ma diventare critico durante recessioni, quando la probabilità di insolvenza aumenta drasticamente. In termini tecnici, l'effetto delle covariate è *condizionale allo stato del mercato*, una forma di non-stazionarietà che i modelli OLS per costruzione non possono catturare.

Il Machine Learning, in particolare il Deep Learning, offre strumenti capaci di modellare queste complessità senza imporre forme funzionali rigide a priori. Gu et al. [1] dimostrano empiricamente che modelli non lineari come le reti neurali superano costantemente i modelli lineari nella previsione dei rendimenti azionari, proprio grazie alla loro capacità di catturare interazioni complesse tra centinaia di predittori e di adattare automaticamente i pesi delle variabili a seconda del regime di mercato. Nel contesto del credito corporate, dove le relazioni tra fondamentali e spread sono intrinsecamente più complesse che nell'equity a causa della sovrapposizione tra rischio di tasso e rischio di credito, l'utilizzo di tecniche avanzate di Machine Learning diventa non solo vantaggioso ma necessario per estrarre segnali predittivi significativi.

4 Machine Learning

Il presente capitolo fornisce le basi metodologiche necessarie per comprendere l'architettura e il funzionamento del modello LSTM utilizzato in questa tesi. Si introducono i concetti fondamentali del Deep Learning, si motiva la scelta delle reti neurali ricorrenti per l'analisi di serie temporali finanziarie e si descrive in dettaglio la struttura LSTM, il processo di addestramento e le metriche di valutazione delle strategie implementate.

4.1 Il Deep Learning nelle Serie Temporali

Architettura delle Reti Neurali

Una **rete neurale** è un modello computazionale ispirato, per analogia, al funzionamento del sistema nervoso biologico. La sua struttura è organizzata in **layer** (strati) sovrapposti, ciascuno composto da unità di calcolo elementari chiamate neuroni artificiali. Ogni neurone riceve un vettore di input, applica una trasformazione matematica — tipicamente una combinazione lineare seguita da una funzione di attivazione non lineare — e propaga il risultato al layer successivo.

Questa architettura stratificata permette alla rete di apprendere rappresentazioni gerarchiche dei dati: i primi layer catturano pattern semplici e locali, mentre i layer più profondi estraono relazioni astratte e globali. Nel contesto finanziario, questo si traduce nella capacità di identificare pattern complessi — come regimi di mercato latenti, correlazioni non lineari tra variabili fondamentali o segnali di stress creditizio emergenti — che sfuggirebbero a modelli lineari tradizionali.

Reti Neurali Ricorrenti: Introduzione

Tra le diverse architetture di Deep Learning, le **Reti Neurali Ricorrenti** (RNN) sono specificamente progettate per trattare dati sequenziali, come le serie storiche dei prezzi obbligazionari. A differenza delle reti Feed-Forward classiche, che processano ogni input in modo indipendente, le RNN mantengono uno *stato nascosto* (hidden state) che trasferisce informazioni da un passo temporale al successivo, creando una forma di memoria a breve termine.

Nel contesto delle serie temporali finanziarie, questa caratteristica è cruciale. Ogni osservazione non è un vettore isolato, bensì parte di una **sequenza** di stati ordinati cronologicamente. Per un modello applicato a dati mensili, una sequenza consiste in una matrice di dimensione $T \times F$, dove T è la **lookback window** (finestra temporale) ed F il numero di features. Ad esempio, con $T = 6$ mesi e $F = 14$ variabili, ogni input al modello è una matrice 6×14 che contiene lo "storico recente" delle condizioni di mercato e dei fondamentali dell'obbligazione. Questa rappresentazione temporale permette al modello di identificare pattern dinamici — come l'inerzia del momentum, l'accumulo progressivo di stress creditizio o la reversione verso la media degli spread — che si manifestano nell'evoluzione temporale delle variabili.

Il Problema del Vanishing Gradient

Tuttavia, le RNN classiche soffrono del problema del **Vanishing Gradient**. Durante la fase di backpropagation, i gradienti utilizzati per aggiornare i pesi della rete si moltiplicano ad ogni passo temporale. Se questi valori sono inferiori a 1, il gradiente decresce esponen-

zialmente (ad esempio, se il gradiente è 0.9, dopo 20 passi temporali $0.9^{20} \approx 0.12$), rendendo impossibile l'apprendimento di dipendenze temporali che si estendono oltre pochi passi. In pratica, una RNN standard non riesce a "ricordare" eventi accaduti più di 10-20 passi nel passato, limitando drasticamente la sua capacità di catturare trend di medio-lungo termine nei mercati finanziari.

4.2 Architettura di un modello LSTM

Per superare il vanishing gradient, Hochreiter e Schmidhuber [10] hanno introdotto le reti **LSTM** (Long Short-Term Memory). L'innovazione chiave è l'introduzione di un *cell state* (stato della cella), un canale separato che attraversa l'intera sequenza temporale con trasformazioni lineari controllate, permettendo ai gradienti di fluire senza degradazione significativa anche su centinaia di passi temporali.

Intuizione: l'analogia con l'analista finanziario

Una LSTM decide attivamente cosa dimenticare (Forget Gate), cosa memorizzare di nuovo (Input Gate) e cosa comunicare (Output Gate), analogamente a un analista che filtra informazioni rilevanti. A differenza di una RNN classica che "dimentica" passivamente, una LSTM apprende autonomamente quali informazioni del passato mantengono rilevanza predittiva e le mantiene attive nella sua memoria a lungo termine.

Formalizzazione matematica: legenda della notazione

Notazione chiave:

- σ : Funzione Sigmoid $\sigma(x) = \frac{1}{1+e^{-x}} \in [0, 1]$ — controlla apertura gate (0 = completamente chiuso, 1 = completamente aperto)
- $\tanh$: Tangente iperbolica $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \in [-1, +1]$ — normalizza simmetricamente l'output, riducendo il vanishing gradient [11]
- $W_{\{f,i,o,c\}}, b_{\{f,i,o,c\}}$: Matrici pesi e bias apprendibili per ciascun gate
- h_{t-1}, x_t : Hidden state precedente (Output della cella al tempo $t-1$) e input corrente
- $\odot$: Prodotto elemento-per-elemento
- C_t : Cell state — memoria a lungo termine

I Tre Gate dell'architettura LSTM

L'unità fondamentale di una LSTM (la "cella") regola il flusso di informazioni attraverso tre *gate* (porte), ciascuna con propri parametri apprendibili:

- **Forget Gate** (f_t): Decide quali informazioni dello stato precedente scartare. Utilizza una funzione sigmoid che produce valori tra 0 e 1. Matematicamente:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (4.1)$$

- **Input Gate** (i_t): Decide quali nuove informazioni dell'input corrente memorizzare nel cell state. Combina una funzione sigmoid (per selezionare cosa aggiornare) con una $\tanh$ (per creare un vettore di valori candidati $\tilde{C}_t$):

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (4.2)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (4.3)$$

- **Output Gate** (o_t): Determina l'output della cella basandosi sullo stato aggiornato:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (4.4)$$

Il cell state viene aggiornato combinando l'informazione dimenticata e quella nuova:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (4.5)$$

Infine, l'hidden state (output della cella) viene calcolato come:

$$h_t = o_t \odot \tanh(C_t) \quad (4.6)$$

Questa struttura permette alle LSTM di imparare *cosa ricordare* (attraverso l'input gate), *cosa dimenticare* (attraverso il forget gate) e *cosa comunicare* (attraverso l'output gate), consentendo la cattura di dipendenze temporali estese su centinaia di passi. Nel contesto finanziario, questo significa che una LSTM può "ricordare" trend o shock di mercato avvenuti molti mesi prima e utilizzarli per la previsione corrente, rendendola ideale per strategie di momentum o mean-reversion nel medio termine.

4.3 Training, Struttura a Layer e Hyperparameter Tuning

Il Processo di Addestramento

Il **training** (addestramento) è il processo attraverso cui il modello apprende dai dati. Durante questa fase, il modello viene esposto ripetutamente ai dati storici, eseguendo un ciclo iterativo strutturato in quattro fasi:

1. **Forward Pass (Passaggio in avanti)**: Le sequenze di input (ad esempio, 6 mesi di features per ciascun bond) attraversano la rete layer per layer, applicando le trasformazioni matematiche definite dall'architettura. Al termine, la rete produce una previsione: il rendimento atteso del bond al mese successivo.
2. **Calcolo della Loss (Errore)**: La previsione viene confrontata con il valore reale osservato. La *Loss Function* — nel presente lavoro, Mean Squared Error (MSE) — quantifica numericamente quanto la previsione si discosta dalla realtà. Un valore alto di loss indica previsioni scadenti.
3. **Backward Pass (Backpropagation)**: Questa è la fase cruciale dell'apprendimento. L'errore viene propagato all'indietro attraverso la rete, calcolando matematicamente (tramite derivate parziali) quanto ciascun peso ha contribuito all'errore totale.
4. **Aggiornamento Pesi**: L'ottimizzatore modifica i parametri della rete nella direzione che riduce l'errore. Questo passo è analogo a un processo di "correzione degli errori": se un peso ha contribuito ad aumentare l'errore, viene ridotto; se ha contribuito a ridurlo, viene rafforzato.

Questo ciclo di quattro fasi è organizzato secondo due livelli gerarchici: **batch** ed **epoche**.

Un **batch** è un sottoinsieme del dataset di training processato simultaneamente. Aniché alimentare le osservazioni una alla volta (estremamente lento) o tutte insieme (impossibile per dataset grandi che non entrano in memoria GPU), si dividono i dati in gruppi di dimensione fissa (ad esempio, 32 o 64 sequenze). Per ogni batch, il modello esegue il forward pass su tutte le osservazioni del gruppo, calcola la loss media e aggiorna i pesi sulla base di questo errore aggregato. L'utilizzo di batch, oltre ad aumentare l'efficienza di risorse, introduce rumore stocastico nel gradiente, il che paradossalmente migliora la generalizzazione prevenendo convergenza prematura verso minimi locali subottimali.

Un'**epoca** (epoch) rappresenta un passaggio completo attraverso l'intero dataset di training. Se il dataset contiene 10.000 osservazioni e si usano batch di dimensione 100, un'epoca consiste in 100 iterazioni di batch ($10.000 / 100 = 100$). Al termine di un'epoca, il modello

ha "visto" ciascuna osservazione esattamente una volta. Il training tipico richiede decine o centinaia di epoche: ad ogni ciclo completo, il modello affina progressivamente i propri pesi, riducendo l'errore di previsione.

Ad esempio, con un dataset di 5.000 sequenze, batch size di 64 e 50 epoche, il training consiste in:

- Iterazioni per epoca: $\lceil 5000/64 \rceil = 79$ batch
- Iterazioni totali: $79 \times 50 = 3950$ aggiornamenti dei pesi

I parametri apprendibili sono i **pesi** (weights), che determinano l'importanza relativa di ciascun input, e i **bias**, che permettono di traslare la funzione di attivazione. L'ottimizzazione avviene tipicamente tramite discesa del gradiente: l'algoritmo calcola la derivata della loss rispetto ai parametri e li modifica nella direzione che riduce più rapidamente l'errore.

Ottimizzazione: l'algoritmo Adam

L'**ottimizzatore** è l'algoritmo che determina *come* aggiornare i parametri della rete durante il training. Gli ottimizzatori moderni [12] superano la semplice discesa del gradiente incorporando due meccanismi chiave: (i) **momentum**, che accumula memoria della direzione di aggiornamento precedente per evitare oscillazioni; (ii) **learning rate adattivo**, che modifica dinamicamente l'ampiezza degli aggiornamenti per ciascun parametro.

Adam (Adaptive Moment Estimation) [13] è lo standard de facto nel Deep Learning moderno perché adatta automaticamente il passo di aggiornamento per ciascun parametro senza necessità di calibrazione manuale estensiva. Questa robustezza è particolarmente rilevante per dati finanziari rumorosi e non-stazionari, dove il meccanismo di smoothing basato su medie mobili esponenziali dei gradienti gestisce efficacemente la volatilità intrinseca dei segnali di mercato.

Learning Rate: Questo iperparametro regola l'ampiezza degli aggiornamenti dei parametri ad ogni iterazione durante l'ottimizzazione, indicando di quanto modificare i pesi della rete nella direzione che riduce l'errore. Il valore $\alpha = 0.001$ (utilizzato in questo lavoro) è empiricamente consolidato come compromesso robusto [13]: valori troppo alti (> 0.01) causano oscillazioni senza convergenza, valori troppo bassi (< 0.0001) rallentano eccessivamente l'apprendimento.

4.4 Applicazione del Modello: Trading Long-Short

La strategia Long-Short è un approccio di investimento *market-neutral* che mira a catturare il rendimento differenziale tra titoli sovra-performanti e sotto-performanti, riducendo l'esposizione direzionale al mercato. L'obiettivo non è prevedere il movimento assoluto dei prezzi obbligazionari, ma *ordinare correttamente* i titoli in base al loro rendimento futuro atteso.

Operativamente, la strategia implementata in questa tesi:

- **Long leg:** Acquista i bond con le previsioni di rendimento più alte
- **Short leg:** Vende allo scoperto i bond con le previsioni più basse, *condizionalmente* al fatto che la previsione media del gruppo sia negativa
- **Rebalancing:** Mensile, con pesi equal-weighted all'interno di ciascun leg

Questa impostazione market-neutral riduce il beta di mercato vicino a zero, isolando l'alpha generato dalla capacità predittiva del modello.

4.5 Metriche di Performance

Le prestazioni del modello vengono valutate su due dimensioni complementari: metriche statistiche, che misurano la precisione delle previsioni, e metriche finanziarie, che quantificano l'implementabilità e la profittabilità della strategia.

Metriche Statistiche

- **MSE** (Mean Squared Error): Misura l'errore quadratico medio tra previsioni $\hat{y}$ e valori realizzati y :

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 \quad (4.7)$$

Penalizza maggiormente gli errori grandi (un errore di 10 bp ha peso 100x rispetto a un errore di 1 bp), risultando sensibile agli outlier. È la loss function standard per problemi di regressione continua.

- R^2 : Frazione di varianza della variabile dipendente spiegata dal modello. Nel contesto finanziario, valori di R^2 tra 0.10-0.30 sono considerati eccellenti data l'elevata rumorosità dei rendimenti. La letteratura ML su equity riporta tipicamente R^2 di 0.05-0.15 (Gu et al. 2020), su bond 0.15-0.25 (Feng et al. 2025).
- **Hit Rate**: Percentuale di predizioni corrette rispetto al segno del rendimento realizzato (positivo/negativo): se il modello predice un rendimento positivo ed effettivamente il rendimento è positivo, la percentuale aumenta, viceversa diminuisce. Misura l'accuratezza direzionale del modello a livello di singolo asset.

Metriche Finanziarie

- **Information Coefficient** (IC): Misura la capacità del modello di ordinare correttamente gli asset in base al loro rendimento futuro [14]. L'IC è definito come la *correlazione di Spearman* (correlazione sui ranghi, non sui valori assoluti) tra le previsioni del modello e i rendimenti realizzati:

$$\text{IC} = \rho_{\text{Spearman}}(\text{Previsioni}, \text{Rendimenti Realizzati}) \quad (4.8)$$

La correlazione di Spearman è preferita a quella di Pearson perché è robusta agli outlier e misura relazioni monotoniche non necessariamente lineari. Per strategie di ranking come il factor investing, un IC positivo indica che il modello ordina correttamente gli asset. Valori tipici nella letteratura accademica sono compresi tra 0.02 e 0.10; valori superiori a 0.10 sono considerati eccellenti [14].

- **Sharpe Ratio** [15]: Rapporto tra il rendimento in eccesso di una strategia e la sua volatilità:

$$\text{Sharpe} = \frac{E[R_p - R_f]}{\sigma_p} \quad (4.9)$$

dove R_p è il rendimento del portafoglio, R_f il tasso risk-free e σ_p la deviazione standard dei rendimenti. Per strategie con rendimenti mensili, lo Sharpe viene annualizzato moltiplicando per $\sqrt{12}$. Uno Sharpe di 1.0 significa che per ogni unità di volatilità assunta si ottiene un'unità di rendimento in eccesso. Per riferimento, l'indice S&P 500 mostra tipicamente uno Sharpe di circa 0.5 su orizzonti decennali, mentre hedge fund tipici si attestano nell'intervallo 0.8-1.5 [16].

- **Maximum Drawdown**: La massima perdita cumulata dal picco al punto più basso del valore del portafoglio. Misura il rischio di perdita estrema della strategia e rappre-

senta una metrica fondamentale per valutare la sostenibilità psicologica e operativa dell'approccio.

- **Win Rate:** Percentuale di periodi in cui la strategia genera rendimenti positivi. Quantifica la consistenza temporale della profittabilità e la frequenza di successo della strategia.

Queste metriche, combinate, permettono di valutare non solo la capacità predittiva del modello LSTM in termini statistici, ma anche la sua traducibilità in strategie implementabili e profittevoli nel periodo di test out-of-sample.

5 Bias e Limitazioni del Machine Learning sul Factor Investing

L'applicazione di tecniche di Machine Learning al Factor Investing nel credito corporate, per quanto promettente, deve confrontarsi con limitazioni metodologiche e bias che possono compromettere la validità dei risultati. Comprendere queste limitazioni è essenziale per interpretare correttamente i risultati empirici e per valutare l'implementabilità delle strategie proposte.

5.1 Bias nella ricerca sui fattori

La ricerca accademica sul Factor Investing, sia nell'equity che nel Fixed Income, è stata recentemente oggetto di un dibattito critico sulla robustezza e replicabilità dei risultati. Numerosi bias metodologici possono gonfiare artificialmente le performance storiche dei fattori, portando a conclusioni ottimistiche che non si traducono in strategie implementabili out-of-sample.

Survivorship Bias

Il **Survivorship Bias** è forse il più insidioso tra i bias strutturali. I database storici di obbligazioni corporate spesso escludono i dati degli emittenti che sono falliti o sono stati delistati nel passato [8]. Ignorare questi fallimenti porta a sovrastimare drasticamente i rendimenti storici, poiché si analizzano solo gli emittenti "sopravvissuti" che, per definizione, non sono andati in default. Questo bias è particolarmente rilevante nel credito, dove i default rappresentano eventi di perdita totale per gli obbligazionisti: escludere tali eventi dal campione significa eliminare proprio le osservazioni più informative sul rischio di coda delle strategie.

Nel mercato obbligazionario europeo, il survivorship bias è amplificato dalla frammentazione dei data provider e dall'assenza di archivi centralizzati obbligatori paragonabili al sistema TRACE statunitense. Nel presente lavoro si è prestata particolare attenzione a utilizzare dataset che includano, dove possibile, anche gli emittenti non più attivi, sebbene la copertura completa rimanga una sfida operativa significativa (si veda la Sezione 6.6 per una discussione dettagliata delle mancanze del campione).

Data Mining Bias e Multiple Testing

Il **Data Mining Bias** si verifica quando i ricercatori testano numerose strategie sullo stesso dataset finché non ne trovano una che funziona per caso statistico. Questo problema è esacerbato dal **Multiple Testing**: se si testano 100 fattori indipendenti con soglia di significatività statistica al 5%, ci si aspetta di trovarne 5 "significativi" per puro caso, anche in assenza di relazioni economiche reali. La letteratura recente ha documentato quella che Jensen et al. [17] definiscono la "Replication Crisis" in finanza: molti fattori pubblicati in articoli accademici perdono significatività quando testati su campioni più ampi o periodi temporali differenti.

Il **P-hacking** rappresenta una forma più sottile di data mining, dove i ricercatori modificano le specifiche del modello, il periodo campionario, o le variabili di controllo fino ad ottenere risultati statisticamente significativi da pubblicare. Tale pratica è incentivata dalla

pressione accademica a produrre risultati "positivi" e dalla difficoltà di pubblicare studi che documentano l'assenza di effetti. Jensen et al. [17] propongono approcci Bayesiani per correggere questi bias, dimostrando che molti fattori mantengono comunque validità anche dopo correzioni stringenti, ma una frazione significativa perde significatività.

Look-ahead Bias e Coerenza Temporale dei Dati

Il **Look-ahead Bias** si verifica quando si utilizzano informazioni che non sarebbero state disponibili al momento della decisione di investimento. Questo bias rappresenta una delle principali fonti di sovrastima delle performance nei modelli predittivi, poiché introduce una contaminazione futura nei dati che invalida la validità out-of-sample dei risultati.

Nel contesto del credito corporate, la coerenza temporale è particolarmente critica a causa dei ritardi sistematici nella pubblicazione delle informazioni fondamentali. I bilanci aziendali trimestrali, ad esempio, vengono pubblicati con ritardi significativi, analogamente, i rating creditizi vengono aggiornati dalle agenzie con ritardi variabili rispetto agli eventi sottostanti: utilizzare un rating "al tempo t " senza considerare quando tale rating è stato effettivamente comunicato al mercato introduce informazioni future nei dati di training.

Nel presente lavoro, le features di mercato (prezzi, spread, duration, momentum) rispettano pienamente la coerenza temporale. Tuttavia, i dati fondamentali (ratio finanziari derivati dai bilanci annuali) sono soggetti a look-ahead bias parziale: i bilanci annuali sono stati propagati (forward fill) per 12 mesi senza incorporare i ritardi di pubblicazione tipici (2-4 mesi). Questo introduce informazione futura nelle features fondamentali, rappresentando una limitazione metodologica che può sovrastimare leggermente la capacità predittiva effettivamente implementabile in condizioni operative reali.

5.2 Requisiti dei Dati per il Machine Learning nel Credito

L'applicazione di tecniche di Machine Learning ai mercati finanziari richiede dataset di dimensioni significativamente maggiori rispetto ai modelli econometrici tradizionali. Come evidenziato da Gu et al. [1], la capacità dei modelli non lineari di catturare pattern complessi dipende criticamente dalla disponibilità di un numero elevato di osservazioni. Questo requisito deriva da due esigenze complementari: il training necessita di dati sufficienti per stimare un numero elevato di parametri senza overfitting, mentre la validazione out-of-sample richiede campioni ampi per distinguere segnali predittivi robusti da artefatti statistici casuali.

Nel contesto del mercato azionario, dove dataset con decine di migliaia di titoli osservati mensilmente per decenni sono disponibili, questa condizione è facilmente soddisfatta. Nel mercato obbligazionario corporate europeo, invece, (i) l'assenza di database unificati obbligatori paragonabili a TRACE, e (ii) la minore longevità media delle serie storiche limitano drasticamente la quantità di dati utilizzabili.

Questa scarsità ha implicazioni dirette sulla scelta dell'architettura del modello. Reti neurali profonde con milioni di parametri, che funzionano efficacemente su dataset equity, rischiano overfitting catastrofico su campioni obbligazionari limitati. La costruzione di un dataset robusto e privo di bias rappresenta pertanto la sfida principale — e spesso sottovalutata — di qualsiasi analisi quantitativa nel credito.

Un ulteriore vincolo tecnico riguarda la struttura delle sequenze temporali richieste dalle architetture LSTM. Queste reti neurali processano finestre temporali consecutive (ad esempio, 6 mesi di features) e sono sensibili alla presenza di valori mancanti: osservazioni incomplete vengono tipicamente interpretate come zero dagli algoritmi di ottimizzazione, introducendo pattern spurie che il modello può erroneamente apprendere come segnali predittivi. Questo problema si sovrappone alla già citata scarsità di dati storici nel mercato

europeo: obbligazioni con copertura intermittente delle variabili fondamentali o con gap nei dati di mercato richiedono tecniche di imputazione o vengono escluse dal campione, riducendo ulteriormente la dimensione effettiva del dataset utilizzabile.

Il Capitolo 6 descrive dettagliatamente le procedure adottate per affrontare queste sfide, inclusi gli algoritmi di matching tra dati di mercato e dati fondamentali, le tecniche di inferenza per valori mancanti, e i filtri applicati per garantire qualità minima delle osservazioni.

5.3 Overfitting e Tecniche di Regularizzazione

L'applicazione di modelli di Machine Learning complessi comporta il rischio centrale di **overfitting**: il modello memorizza pattern idiosincratici e rumore del training set invece di apprendere relazioni strutturali generalizzabili. Questo fenomeno è particolarmente insidioso con dataset finanziari limitati, dove la capacità espressiva della rete neurale supera la quantità di informazione disponibile per vincolare i parametri in modo univoco.

Manifestazioni dell'overfitting

L'overfitting si manifesta tipicamente quando:

- La **complessità del modello** (numero di parametri) è eccessiva rispetto alla quantità di dati disponibili. La letteratura statistica classica raccomanda un rapporto minimo di 10:1 tra osservazioni e parametri per garantire generalizzazione robusta e ridurre il rischio di overfitting; applicazioni industriali di ML mirano tipicamente a rapporti di 50:1 o superiori. Con tecniche di regularizzazione aggressive (dropout, early stopping, weight decay) questo vincolo può essere parzialmente allentato, ma rimane una soglia critica sotto la quale il rischio di memorizzazione di pattern idiosincratici aumenta significativamente.
- Il **training prosegue troppo a lungo**, permettendo al modello di adattarsi progressivamente anche al rumore casuale presente nei dati. Nelle fasi iniziali del training, il modello apprende pattern generalizzabili; nelle fasi avanzate, inizia a memorizzare fluttuazioni idiosincratice.
- Le **features di input contengono informazioni spurie o altamente collineari**, che permettono al modello di costruire rappresentazioni complesse basate su correlazioni accidentali anziché su relazioni causali.

Il sintomo diagnostico dell'overfitting è un'eccellente performance in-sample e un collasso predittivo out-of-sample: il modello funziona perfettamente sui dati storici utilizzati per il training ma fallisce sistematicamente nel predire dati mai visti.

Data Leakage

Un problema critico correlato è il **data leakage**: contaminazione incrociata tra dati di training e testing che gonfia artificialmente le performance out-of-sample. Nel contesto del Machine Learning applicato al credito, questo problema assume forme subdole. Ad esempio, la normalizzazione delle features (standardizzazione con media e deviazione standard) deve essere eseguita esclusivamente sui dati di training; applicare la normalizzazione sull'intero dataset prima dello split temporale introduce leakage, poiché le statistiche calcolate incorporano informazioni future. Analogamente, la selezione delle features basata su correlazioni con la variabile target deve avvenire esclusivamente sul training set, altrimenti si introducono bias di selezione che gonfiano la performance apparente.

Tecniche di regolarizzazione adottate

Per contrastare l'overfitting, si ricorre a tecniche di **regolarizzazione**. Nel presente lavoro sono state adottate le seguenti contromisure:

- **Dropout** [18]: Durante l'addestramento, una frazione casuale dei neuroni (50% nel modello implementato) viene temporaneamente disattivata ad ogni iterazione. Questo impedisce la co-adattazione eccessiva tra neuroni specifici e forza la rete a sviluppare rappresentazioni più robuste e ridondanti. Un dropout rate aggressivo (50% vs i classici 20%/30%) è appropriato per dataset finanziari di piccola dimensione dove il rischio di overfitting è elevato.
- **Early Stopping** [12]: L'addestramento viene interrotto quando l'errore su un set di validazione — dati tenuti da parte e non utilizzati per l'ottimizzazione dei pesi — smette di migliorare per un numero prefissato di epoche consecutive. Questo previene l'overfitting nelle fasi avanzate del training: il modello potrebbe continuare a migliorare sui dati di training memorizzando pattern specifici e rumore, ma peggiorerebbe su dati nuovi. L'early stopping identifica automaticamente il punto ottimale di arresto, bilanciando capacità espressiva e generalizzabilità.
- **Architettura parsimoniosa**: Seguendo il principio del **rasoio di Occam** [19], tra modelli con capacità predittiva simile, il più semplice è preferibile perché tende a generalizzare meglio, questo perché modelli con meno parametri hanno minore capacità di memorizzare pattern idiosincratici e rumore presente nei dati di training, essendo vincolati a catturare solo le relazioni più robuste e sistematiche. Nel Machine Learning, questo principio si traduce nel trade-off bias-varianza: modelli troppo complessi riducono il bias (errore sistematico) ma aumentano la varianza (sensibilità ai dati di training), portando a overfitting.
- **Feature selection**: La riduzione del numero di variabili di input elimina informazioni spurie e riduce la dimensionalità del problema di ottimizzazione, facilitando la convergenza e riducendo il rischio di memorizzazione del rumore (si veda il Capitolo 7 per i criteri di selezione adottati).

Queste contromisure non sono opzionali: rappresentano componenti metodologiche essenziali per garantire la validità statistica dei risultati in contesti finanziari, dove la tentazione di sovra-adattare i dati è amplificata dall'alto rapporto rumore-segnale e dalla non-stazionarietà dei mercati. La sezione di validazione out-of-sample (Capitolo 9) fornirà evidenza empirica dell'efficacia di tali tecniche nel contenere l'overfitting del modello implementato.

6 Dati

La costruzione di un dataset robusto e privo di bias rappresenta la sfida principale — e spesso sottovalutata — di qualsiasi analisi quantitativa nel credito corporate europeo. La pipeline implementata comprende diverse fasi.

6.1 Fonti Dati e Universo Investibile

Il dataset finale è stato costruito integrando tre fonti complementari, ciascuna selezionata per specifiche caratteristiche di copertura e affidabilità. Bloomberg Terminal, pur rappresentando lo standard industriale per dati real-time, non è stato utilizzato a causa delle stringenti limitazioni nell'estrazione massiva di serie storiche profonde, necessarie per il training di modelli di Machine Learning.

Cbonds: Anagrafica e Prezzi Obbligazionari

Cbonds [20] rappresenta la fonte primaria per l'anagrafica obbligazionaria e per i prezzi storici. Il database fornisce dati su 30,280 obbligazioni corporate europee iniziali, con copertura temporale 2005-2025. La Tabella 6.1 riassume i campi estratti.

Tabella 6.1: Dati estratti da Cbonds

Categoria	Campo	Formato
Anagrafica	ISIN	Identificativo univoco (12 caratteri)
	Emittente	Nome dell'emittente
	Data Emissione	Data di emissione del titolo
	Data Scadenza	Data di rimborso a scadenza
	Coupon Rate	Tasso cedolare annuo (%)
	Coupon Frequency	Frequenza pagamento cedole
	Valuta	Valuta di denominazione
	Face Value	Valore nominale
	Paese	Paese dell'emittente
Prezzi Storici	Clean Price	Prezzo di mercato
	Data	Osservazioni mensili

La scelta di utilizzare osservazioni a **frequenza mensile** è motivata da: (i) riduzione del rumore nei dati giornalieri OTC, dove i prezzi sono spesso indicativi; (ii) maggior compatibilità con la periodicità dei dati fondamentali (bilanci annuali).

WRDS/Compustat Global: Dati Fondamentali

WRDS/Compustat Global [21] fornisce i dati fondamentali degli emittenti ed azionari degli stessi.

Da questa fonte sono stati estratti:

- Dati di bilancio a **frequenza annuale**: 11 metriche fondamentali comprendenti Total Assets, Total Debt, Operating Income, EBITDA, Book Value, Cash & Equivalents, Current Assets, Current Liabilities, Revenue, Net Income, Interest Expense. L'elenco completo delle metriche grezze con codici WRDS è riportato nella Tabella 6.2.

- Dati di mercato equity a **frequenza mensile**: prezzi di chiusura, massimi e minimi, volumi. Questi dati, sebbene estratti, non sono stati utilizzati nel modello finale.

L'estrazione iniziale ha coinvolto tutti gli emittenti disponibili sul database Comèustat Global accessibile tramite WRDS

Tabella 6.2: Metriche grezze estratte da WRDS/Compustat Global

Categoria	Variabile	Codice WRDS	Descrizione
Stato Patrimoniale	Total Assets	at	Attivi totali dell'emittente
	Total Liabilities	lt	Passività totali
	Total Debt	dt	Debito totale (short-term + long-term)
	Current Assets	act	Attivi correnti (liquidità, crediti, rimanenze)
	Current Liabilities	lct	Passività correnti
	Inventories	inv	Rimanenze di magazzino
	Book Value	ceq	Patrimonio netto contabile (Common Equity)
	Cash & Equivalents	che	Disponibilità liquide
Conto Economico	Revenue	sale	Ricavi totali
	EBITDA	oibdp	Margine operativo lordo (Op. Inc. bef. Dep.)
	Operating Income (EBIT)	ebit	Risultato operativo (Op. Inc. aft. Dep.)
	Net Income	ni	Utile netto
	Interest Expense	xint	Oneri finanziari
	Capital Expenditures	capx	Investimenti in capitale fisso
	Earnings Per Share	epspx	Utile per azione (diluito)
Altro	Employees	emp	Numero dipendenti
Dati Equity	Price Close (Monthly)	prccm	Prezzo di chiusura mensile
	Trading Volume	cshtd	Volume di scambio mensile

ECB Statistical Data: Tassi Risk-Free e Reference Rates

ECB Statistical Data [3] fornisce le curve dei tassi risk-free ufficiali dell'Eurozona (AAA Euro Area Yield Curves) su scadenze da 3 mesi a 30 anni, necessarie per il calcolo accurato dello Z-Spread, per l'attualizzazione dei flussi di cassa e per il calcolo dello Sharpe Ratio. Sono state inoltre estratte serie storiche dei reference rate per titoli a tasso variabile (EURIBOR a varie scadenze e indice STOXX50).

6.2 Preprocessing dei Dati Grezzi

Questa sezione descrive le operazioni di pulizia e standardizzazione applicate ai dati grezzi di ciascuna fonte, propedeutiche al successivo matching e calcolo delle variabili derivate.

Riepilogo Operazioni di Preprocessing

La Tabella 6.3 riassume le operazioni di pulizia e standardizzazione applicate a ciascuna fonte dati.

Tabella 6.3: Operazioni di preprocessing per fonte dati

Fonte	Operazioni
Anagrafica	ISIN standardizzati (maiuscolo), date validate (ISO format), tasso/valore nominale convertiti a numerico, classificazione tipo (Fixed/Floating/Zero Coupon)
Prezzi	Conversione wide→long format, aggregazione mensile (ultimo giorno trading), gestione duplicati (media aritmetica), rimozione valori mancanti
Dati WRDS	Conversione formato europeo→decimale, estrazione gvkey, forward-fill annuale (bilanci propagati 12 mesi)
Curve ECB	Interpolazione lineare (maturities intermedie), estrapolazione piatta (oltre 30 anni)

6.3 Matching Bond-Finanziari: Algoritmo Tri-Livello

Una delle complessità maggiori del processo di costruzione del dataset riguarda l'integrazione tra dati obbligazionari (identificati da ISIN) e dati societari (identificati da GVKEY Compustat), in assenza di una chiave univoca comune. È stata implementata una procedura di matching probabilistico a tre livelli che opera sul nome dell'emittente, riassunta nella Tabella 6.4.

Tabella 6.4: Algoritmo di matching tri-livello Bond-Finanziari

Livello	Metodo	Descrizione
1. Exact Match	Corrispondenza esatta	Normalizzazione Unicode NFD, match case-insensitive dopo rimozione spazi e caratteri non alfanumerici
2. Suffix Removal	Rimozione suffissi legali	Applicazione lista predefinita di suffissi (S.E., A.G., S.p.A., GmbH, Ltd., PLC, Inc., Corp., N.V., S.A.), retry matching
3. Fuzzy Match	Similarità testuale	Algoritmo rapidfuzz (Levenshtein Distance), soglia 90/100, validazione manuale match sopra soglia

Risultato del matching: Da 28,629 obbligazioni candidate, 13,139 (45.9%) sono state matched con successo ai dati fondamentali WRDS. Le obbligazioni non matched sono state escluse dal dataset finale.

6.4 Dati Derivati: Prospetti, Metriche e Factors

A partire dai dati grezzi preprocessati e matched, è stata costruita una serie di variabili derivate necessarie per la modellazione. Questa sezione descrive la metodologia teorica e implementativa utilizzata per il calcolo delle metriche obbligazionarie e dei fattori finanziari.

Creazione Calendario Cedole

Per ogni obbligazione viene generato un calendario completo dei pagamenti futuri, necessario per il calcolo dello Z-Spread e della duration. Il processo distingue tre tipologie cedolari:

- **Fixed Rate:** Pagamenti a frequenza definita (annuale, semestrale, trimestrale) e importo costante calcolato come $\text{Cedola} = \text{Face Value} \times \text{Coupon Rate} / \text{Frequency}$.
- **Floating Rate:** Parsing di formule standard (es. "EURIBOR 6M + 150 bps"). Sono stati processati esclusivamente titoli con reference rate comuni europei (EURIBOR, STOXX50); strutture complesse (cap/floor, spread variabili, multiple reference) sono state escluse per impossibilità di parsing automatico affidabile.
- **Zero Coupon:** Unico flusso a scadenza pari al valore nominale.

Per ciascun pagamento futuro vengono calcolate:

- *Time-to-Payment:* Anni residui a ciascun pagamento dalla data di valutazione, essenziale per il discounting nei calcoli DCF (Discounted Cash Flow).
- *Coupon Amount:* Importo monetario stimato del flusso di cassa, utilizzando il reference rate corrente per titoli floating rate.

Calcolo del Tasso Interno di Rendimento (YTM)

Il Yield to Maturity rappresenta il tasso di sconto che eguaglia il valore attuale dei flussi futuri al prezzo di mercato osservato. Viene calcolato risolvendo numericamente:

$$\text{Prezzo Mercato} = \sum_{i=1}^n \frac{\text{Cedola}_i}{(1 + \text{YTM})^{t_i}} + \frac{\text{Valore Nominale}}{(1 + \text{YTM})^T} \quad (6.1)$$

dove t_i sono i tempi di pagamento in anni e T è la scadenza residua.

Implementazione numerica:

- Metodo: Brent's method (`scipy.optimize.brentq`)
- Intervallo di ricerca: $[0.001, 0.5]$ (0.1% - 50% annuo)
- Gestione errori: NaN se il solver non converge dopo 100 iterazioni

Interpolazione della Curva Risk-Free

Il calcolo dello Z-Spread richiede tassi risk-free spot per ogni scadenza corrispondente ai flussi di cassa dell'obbligazione. Le curve ECB sono disponibili solo su scadenze standard discrete (3m, 6m, 1y, 2y, 3y, 5y, 7y, 10y, 15y, 20y, 30y), rendendo necessaria l'interpolazione per scadenze intermedie.

Per ogni scadenza richiesta t^* , il tasso risk-free $r(t^*)$ viene determinato mediante:

- **Interpolazione lineare:** Per $t_1 < t^* < t_2$ tra due scadenze disponibili:

$$r(t^*) = r(t_1) + \frac{t^* - t_1}{t_2 - t_1} \cdot [r(t_2) - r(t_1)] \quad (6.2)$$

- **Estrapolazione piatta:** Per scadenze oltre 30 anni o sotto 3 mesi, si utilizza il tasso del punto estremo più vicino ($r(30y)$ o $r(3m)$ rispettivamente).

L'interpolazione lineare è standard nella pratica di mercato ma presenta limitazioni: produce discontinuità nelle derivate nei punti nodali e l'estrapolazione piatta può distorcere lo Z-Spread per bond con scadenze molto lunghe se la curva teorica presenta slope oltre 30 anni. Approcci più sofisticati (spline cubiche, modello di Svensson) produrrebbero curve più lisce ma richiederebbero calibrazione di parametri aggiuntivi. Il metodo adottato rappresenta un compromesso accettabile tra accuratezza e semplicità implementativa, coerente con le convenzioni di mercato per dataset ampi.

Calcolo dello Z-Spread

La misura di spread utilizzata in questo lavoro è lo **Z-Spread** (Zero-volatility spread), definito come lo spread costante che deve essere aggiunto a ogni punto della curva dei tassi spot zero-coupon risk-free per eguagliare il valore attuale dei flussi di cassa al prezzo di mercato dell'obbligazione. Formalmente:

$$\text{Prezzo Mercato} = \sum_{i=1}^n \frac{\text{Cedola}_i}{(1 + \text{RFR}_i + \text{Z-Spread})^{t_i}} + \frac{\text{Valore Nominale}}{(1 + \text{RFR}_T + \text{Z-Spread})^T} \quad (6.3)$$

dove RFR_i è il tasso risk-free interpolato dalle curve ECB alla scadenza dell' i -esimo flusso.

Implementazione numerica:

- Metodo: Brent's method
- Intervallo di ricerca: $[-0.10, 1.00]$ (-10% a +100%)
- Validazione: Z-spread calcolato solo se prospetto flussi completo e curve RFR disponibili

In teoria, la misura più accurata per isolare il puro rischio di credito sarebbe l'**Option-Adjusted Spread (OAS)**, che depura il rendimento dal valore di eventuali opzioni incorporate nel titolo. Molte obbligazioni corporate includono opzioni call (che permettono all'emittente di rimborsare anticipatamente) o put (che permettono all'investitore di richiedere rimborso anticipato). L'OAS utilizza modelli di pricing opzionale per "sottrarre" questo valore, isolando il puro compenso per il rischio di credito.

Tuttavia, il calcolo dell'OAS richiede: (i) un modello stocastico per i tassi di interesse, (ii) la struttura completa delle opzioni incorporate in ogni singola obbligazione, (iii) le caratteristiche specifiche di esercizio delle suddette opzioni. In assenza di questi dati, è stato utilizzato lo Z-Spread come proxy (si veda Assunzione 6.5 per dettagli metodologici e limitazioni).

Calcolo della Duration

La duration misura la sensibilità percentuale del prezzo di un'obbligazione a variazioni dei tassi di interesse. Sono state calcolate entrambe le misure standard:

- **Duration Macaulay:** Media ponderata dei tempi di pagamento, pesati per il valore attuale di ciascun flusso:

$$D_{\text{Mac}} = \frac{1}{P} \sum_{i=1}^n t_i \frac{CF_i}{(1+y)^{t_i}} \quad (6.4)$$

dove P è il prezzo, CF_i sono i flussi di cassa, y è il YTM e t_i i tempi di pagamento.

- **Duration Modificata:** Approssimazione lineare della variazione percentuale di prezzo per variazione unitaria del rendimento:

$$D^* = \frac{D_{\text{Mac}}}{1+y} \quad (6.5)$$

Calcolo della Convessità

La convessità misura la curvatura della relazione prezzo-rendimento, catturando effetti di secondo ordine ignorati dalla duration. Viene calcolata come derivata seconda del prezzo rispetto al rendimento, normalizzata per il prezzo:

$$C = \frac{1}{P} \sum_{i=1}^n t_i(t_i + 1) \frac{CF_i}{(1+y)^{t_i+2}} \quad (6.6)$$

La convessità è utilizzata per aggiustamenti di ordine superiore nelle stime di sensibilità al tasso, particolarmente rilevanti per shock di rendimento significativi.

Metriche Finanziarie Aziendali

Dopo il matching bond-finanziari, per ogni obbligazione sono state calcolate metriche fondamentali derivate dai dati di bilancio. I ratio finanziari calcolati sono:

- **Leva Finanziaria:** $\text{Debt/Assets} = \frac{\text{Total Debt}}{\text{Total Assets}}$
- **Copertura Interessi:** $\text{EBIT/Interest} = \frac{\text{EBIT}}{\text{Interest Expense}}$
- **ROA:** $\text{Return on Assets} = \frac{\text{Net Income}}{\text{Total Assets}}$
- **Capitale Circolante/Assets:** $\frac{\text{Current Assets} - \text{Current Liabilities}}{\text{Total Assets}}$
- **Margine Operativo:** $\frac{\text{EBIT}}{\text{Revenue}}$
- **Cash/Assets:** $\frac{\text{Cash \& Equivalents}}{\text{Total Assets}}$
- **EBITDA/Debt:** $\frac{\text{EBITDA}}{\text{Total Debt}}$

Factors

Le features di factor investing catturano diverse dimensioni del rischio e del rendimento obbligazionario, ispirandosi alla letteratura sul Fixed Income Factor Investing [7], [8]. Nella fase di costruzione del dataset sono state calcolate tutte le 58 features statisticamente significative identificate nel paper OSBAP (Open Source Bond Asset Pricing) [22], che costituisce uno standard di riferimento per la ricerca empirica sul credito corporate. Le sottosezioni seguenti descrivono le features effettivamente selezionate e utilizzate nel modello finale dopo il processo di feature selection discusso nel Capitolo 7.

Features di Momentum

Le variabili di momentum catturano la persistenza dei rendimenti su diversi orizzonti temporali:

$$\text{Mom}_{0-1m} = \log(\text{Prezzo}_t) - \log(\text{Prezzo}_{t-1m}) \quad (6.7)$$

$$\text{Mom}_{1-3m} = \log(\text{Prezzo}_{t-1m}) - \log(\text{Prezzo}_{t-3m}) \quad (6.8)$$

Questi momentum "skip" evitano l'effetto di microreversione a brevissimo termine documentato nella letteratura.

Duration Times Spread (DTS)

Un'altra metrica fondamentale è la **DTS (Duration Times Spread)**, definita come:

$$\text{DTS} = \text{Spread Duration} \times \text{Spread} \quad (6.9)$$

dove la Spread Duration misura la sensibilità percentuale del prezzo a una variazione dell'1% degli spread creditizi. Questa metrica è stata originariamente introdotta da Ben Dor et al. [23] ed è una misura consolidata per prevedere volatilità creditizia [7]. L'intuizione è che le variazioni degli spread tendono ad essere *proporzionali* al livello corrente dello spread, non costanti in valore assoluto: un bond con spread elevato sperimenterà variazioni di spread maggiori rispetto a un bond con spread basso.

Volatilità dello Spread

La volatilità dello Z-Spread su finestra rolling di 12 mesi misura l'incertezza percepita dal mercato sulla qualità creditizia dell'emittente, calcolata come deviazione standard delle variazioni mensili dello spread.

6.5 Le Assunzioni

A1: Media Aritmetica per Prezzi Multipli

Quando per uno stesso bond sono stati osservati multipli prezzi di chiusura nello stesso mese, è stata calcolata la media aritmetica come proxy del prezzo rappresentativo. Ciò può avvenire per casi in cui uno stesso bond viene listato su borse diverse.

Giustificazione: In assenza di dati sui volumi scambiati, la media aritmetica fornisce una stima imparziale del prezzo centrale di mercato.

Limitazione: La media aritmetica può essere influenzata da quotazioni outlier di dealer con pricing anomalo.

A2: Tasso Risk-Free Unico per Tutte le Giurisdizioni

È stata utilizzata la curva ECB AAA Euro Area come unico tasso risk-free per tutte le obbligazioni nell'universo europeo, indipendentemente dal paese di incorporazione dell'emittente.

Giustificazione: Questa semplificazione evita la frammentazione del dataset su multiple curve nazionali e garantisce comparabilità cross-country. Per un investitore che opera su diverse borse europee, la curva AAA rappresenta il benchmark privo di rischio naturale. In assenza di un aggregatore centralizzato che fornisca serie storiche complete per tutte le curve nazionali, la raccolta manuale avrebbe aumentato significativamente i requisiti di risorse introducendo problemi di armonizzazione metodologica.

Limitazione: Per emittenti di paesi periferici (Italia, Spagna, Portogallo), lo spread calcolato rispetto alla curva AAA incorporerà implicitamente anche il sovereign spread del paese di origine, sovrastimando il rischio idiosincratico dell'emittente. Analogamente, per i titoli a tasso variabile sono stati utilizzati esclusivamente reference rate comuni europei (EURIBOR, STOXX50), limitando significativamente la copertura dei bond floating rate (si veda la discussione approfondita nella sezione "Sotto-rappresentazione Floating Rate").

A3: Face Value Inferito da Ordine di Grandezza Prezzo

CBonds mostra dati sui valori nominali sporadici e, dove presenti, i valori risultano costantemente anomali e ritenuti completamente inaffidabili; per questo motivo, il valore nominale è stato inferito dall'ordine di grandezza del prezzo osservato:

- Prezzo nell'ordine delle unità/decine (es. 98.2) $\rightarrow$ Face Value = 100
- Prezzo nell'ordine delle centinaia (es. 1,005) $\rightarrow$ Face Value = 1,000
- Prezzo nell'ordine delle migliaia (es. 9,954) $\rightarrow$ Face Value = 10,000

A4: Z-Spread come Proxy per Rischio Credito

In assenza di informazioni sui prospetti obbligazionari (clausole call, put, schedule di esercizio), è stato utilizzato lo Z-Spread anziché l'Option-Adjusted Spread (OAS).

Giustificazione: Il calcolo dell'OAS richiede (i) modello stocastico dei tassi di interesse, (ii) struttura completa delle opzioni embedded, (iii) caratteristiche di esercizio. Per obbligazioni plain vanilla senza opzioni significative, lo Z-Spread è un'approssimazione accettabile del rischio di credito.

Limitazione: Per titoli callable o puttable, questa approssimazione introduce imprecisioni. L'OAS di un bond callable sarebbe sistematicamente inferiore al suo Z-Spread (poiché parte dello spread compensa l'opzione venduta all'emittente), sovrastimando il puro rischio di credito.

A5: Forward Fill per Dati di Bilancio Annuali

I dati di bilancio annuali sono stati propagati (forward fill) per tutti i 12 mesi successivi fino alla pubblicazione del nuovo bilancio.

Giustificazione: Garantisce continuità informativa tra pubblicazioni annuali. Riflette la realtà operativa: gli investitori utilizzano l'ultimo bilancio disponibile fino all'aggiornamento successivo.

Limitazione: Non cattura variazioni infrannuali della situazione finanziaria dell'emittente. Eventi significativi (acquisizioni, ristrutturazioni) avvenuti dopo la pubblicazione del bilancio non sono riflessi nelle metriche fino al bilancio successivo.

A6: Rimborso Integrale del Capitale

In assenza di informazioni specifiche su piani di ammortamento o opzioni di rimborso anticipato esercitate, si assume che tutte le obbligazioni rimborsino l'intero valore nominale (100% del face value) in un'unica soluzione alla data di scadenza naturale del titolo (*bullet repayment*).

Giustificazione: Questa assunzione è necessaria per la costruzione coerente dei flussi di cassa (DCF) utilizzati nel calcolo dello YTM e dello Z-Spread.

Limitazione: Ignora bond con ammortamento graduale (amortizing bonds) o con call/put effettivamente esercitate durante il periodo di osservazione.

6.6 Limiti dei Dati e Mancanze del Campione

La costruzione del dataset ha dovuto affrontare severi limiti strutturali che influenzano l'interpretazione dei risultati e la generalizzabilità delle conclusioni.

Mancanza di Volumi e Bid-Ask

Cbonds fornisce prezzi di chiusura (spesso indicativi) ma non i volumi scambiati né gli spread denaro-lettera storici. Questo impedisce di modellare accuratamente la liquidità e i costi di transazione reali, portando a una potenziale sovrastima dei rendimenti netti implementabili. L'assenza di dati sui volumi preclude inoltre la costruzione di proxy affidabili per il fattore Size, che in letteratura viene talvolta misurato attraverso la liquidità delle emissioni anziché la capitalizzazione dell'emittente.

Rating Point-in-Time

L'indisponibilità di una storia completa dei rating creditizi con date di modifica rappresenta una limitazione significativa per molteplici ragioni. I rating creditizi svolgono un ruolo centrale nel mercato obbligazionario corporate: (i) costituiscono input fondamentale per il calcolo di numerosi factor di rischio e strategie di investimento documentate in letteratura; (ii) rappresentano una discriminante operativa cruciale per gli investitori istituzionali — fondi pensione, compagnie assicurative, gestori patrimoniali — che sono soggetti a stringenti vincoli regolamentari sulla qualità creditizia minima degli asset detenibili (ad esempio, requisiti di detenzione esclusiva di titoli investment-grade con rating BBB- o superiore); (iii) dato che gli investitori istituzionali rappresentano la categoria dominante nel mercato corpo-

rate europeo in termini di volumi scambiati e asset under management, i rating influenzano direttamente la liquidità e il pricing dei titoli attraverso vincoli di domanda strutturali.

L'assenza di serie storiche point-in-time dei rating ha costretto all'uso di proxy alternative basate su metriche di bilancio (leverage, coverage ratios, profitability) per catturare la qualità creditizia. Questo approccio limita la precisione del fattore Quality/Defensive per due motivi: (i) i rating ufficiali incorporano informazioni qualitative (governance, posizionamento competitivo, valutazioni forward-looking) non osservabili nei bilanci storici; (ii) le proxy contabili non catturano i cambiamenti discreti di rating che generano flussi di ribilanciamento forzato da parte di investitori vincolati, eventi rilevanti per la dinamica degli spread.

Universo Limitato

Il campione finale ha poche centinaia di titoli, rappresentando una frazione ridotta dell'universo globale di obbligazioni corporate europee (stimato in diverse migliaia di emissioni attive). Questa riduzione è il risultato dei filtri applicati per garantire completezza dei dati (matching emittente riuscito, disponibilità metriche di bilancio, continuità delle serie storiche), introducendo un potenziale *Selection Bias*.

La direzione del bias non è determinabile a priori: da un lato, gli emittenti matched con Compustat tendono ad essere società più grandi e trasparenti, potenzialmente meno rischiose; dall'altro, il requisito di serie storiche complete esclude bond di breve durata o recente emissione, potenzialmente alterando la distribuzione per maturity. L'impatto netto sulla rappresentatività del campione rispetto all'universo investibile va considerato nell'interpretazione dei risultati.

Assenza di Dati su Opzioni Embedded

L'indisponibilità di informazioni sulle opzioni incorporate (call provisions, put provisions, schedule di esercizio) impedisce sia il calcolo dell'OAS sia la corretta esclusione o identificazione dei titoli callable/puttable nel campione. Come discusso nell'Assunzione 6.5, questo introduce imprecisioni nelle misure di spread per titoli con optionality significativa.

Survivorship Bias

Teoricamente Cbonds include nel database titoli delisted e matured, tuttavia non è stato possibile verificarlo. È possibile che emittenti falliti prima dell'inizio del periodo di copertura (ante-2005) o con caratteristiche particolari (es. bond convertibili poi convertiti) siano sottorappresentati. Questo bias, se presente, tenderebbe a sovrastimare i rendimenti storici del campione poiché escluderebbe le peggiori performance.

Assenza di Prospetti Informativi e Calcolo Sintetico delle Cedole

L'assenza di accesso ai prospetti informativi ufficiali rappresenta una limitazione critica. I prospetti contengono la documentazione completa dei termini contrattuali (schedule esatto dei pagamenti cedolari, covenant, trigger events, piani di ammortamento), informazioni non disponibili nei metadati Cbonds. Tutti i flussi di cassa cedolari sono stati quindi calcolati **sinteticamente** mediante la formula standard:

$$\text{Cedola} = \frac{\text{Face Value} \times \text{Coupon Rate}}{\text{Frequency}} \quad (6.10)$$

Questo approccio introduce molteplici fonti di imprecisione:

- **Day count conventions:** La formula assume implicitamente Actual/Actual, ma molti bond utilizzano 30/360 o Actual/360, introducendo discrepanze di pochi basis point.
- **Cedole irregolari e step-up:** Bond con first/last coupon irregolari o cedola crescente nel tempo sono trattati erroneamente come fixed-rate costanti.
- **Business day conventions:** Le date di pagamento sono stimate sinteticamente senza conoscere le regole effettive (Modified Following, Following, Preceding), introducendo errori di pochi giorni che possono accumularsi su scadenze lunghe.
- **Impossibilità di identificare call/put:** Come discusso nell'Assunzione 6.5, il campione include un numero sconosciuto di bond callable/puttable per i quali lo Z-Spread è distorto.

Le implicazioni sono duplici: (i) le metriche derivate dai flussi di cassa (YTM, Z-Spread, Duration, Convexity) contengono errore sistematico di misurazione, presumibilmente piccolo (pochi basis point) per la maggioranza dei titoli ma potenzialmente significativo per strutture complesse; (ii) la replicazione esatta delle strategie richiederebbe accesso ai prospetti per calcolare correttamente i flussi attesi.

Sotto-rappresentazione Floating Rate

La quasi totale assenza di titoli a tasso variabile nel campione finale (0.5% vs 15-20% del mercato) rappresenta una limitazione significativa dovuta a vincoli operativi e metodologici:

1. **Assenza di prospetti standardizzati:** molti bond non forniscono formule cedolari complete nei database, richiedendo accesso a prospetti informativi dettagliati non disponibili su larga scala.
2. **Complessità del parsing:** formule non standard (cap/floor, spread variabili, multiple reference rates) richiedono logiche di parsing complesse e case-by-case non automatizzabili senza accesso ai prospetti ufficiali.
3. **Limitazione dei reference rate:** Per il calcolo sintetico dei flussi cedolari dei titoli a tasso variabile sono stati estratti esclusivamente reference rate comuni europei (EURIBOR, STOX50). Molti bond floating rate utilizzano reference rate nazionali o settoriali specifici (tassi interbancari nazionali, indici settoriali, tassi governativi), la cui integrazione avrebbe richiesto la raccolta di diverse decine di serie storiche da fonti frammentate senza disponibilità di aggregatori centralizzati. Bond indicizzati a questi tassi specifici sono stati esclusi per impossibilità di reperire serie storiche complete e armonizzate metodologicamente.

Questa scelta operativa ha permesso di mantenere coerenza metodologica e replicabilità accessibile, al costo di precludere l'analisi di una porzione significativa del mercato corporate europeo. I risultati della tesi si applicano quindi primariamente al segmento fixed-rate, che rimane tuttavia il segmento predominante (oltre l'80%) del mercato corporate EUR Investment Grade.

6.7 Considerazioni sul Dataset finale

Il processo di selezione ha ridotto progressivamente l'universo iniziale per garantire qualità dei dati:

- **Universo Iniziale:** 30,280 obbligazioni corporate (Cbonds raw data)
- **Dopo Preprocessing Prezzi:** 14,700 obbligazioni con serie storiche di prezzi mensili

- **Dopo Matching Fondamentali:** 13,139 obbligazioni matched con successo a Compustat (45.9%)
- **Dopo Filtri Qualità:** 439 obbligazioni uniche con copertura completa features
- **Totale Osservazioni:** 30,587 coppie obbligazione-mese

Composizione per dimensioni principali:

- **Tipologia cedola:** Fixed Rate 97.7%, Zero-Coupon 1.8%, Floating Rate 0.5%
- **Paese emittente:** Regno Unito 31.2%, Germania 21.9%, Francia 14%, Svizzera 6.4%, Paesi Bassi 5%, altri 21.1%
- **Valuta:** EUR 60.6%, USD 28.0%, GBP 6.8%, CHF 4.3%, altre 3%

La netta predominanza di titoli a cedola fissa riflette sia una caratteristica strutturale del mercato europeo sia le limitazioni nel parsing delle formule cedolari complesse discusse nella sezione precedente.

6.8 Gestione dei Valori Mancanti e Rimozione NaN Iniziali

Anche dopo le procedure di interpolazione e stima descritte nelle sezioni precedenti, le serie temporali presentano due tipologie residue di valori mancanti che richiedono trattamento specifico: (i) NaN sporadici all'interno delle serie, gestiti tramite forward-fill, e (ii) NaN iniziali sistematici derivanti dalla natura retrospettiva delle features calcolate.

NaN Iniziali (Leading NaN Trimming)

Le prime osservazioni di ciascuna serie temporale presentano sistematicamente valori mancanti per vincolo strutturale. Alcune features richiedono finestre retrospettive di dati storici per essere calcolate:

- **Momentum 1-3m:** Richiede almeno 3 mesi di storico dei prezzi ($\log(P_{t-1}/P_{t-3})$)
- **Spread Volatility (12M):** Richiede finestra rolling di 12 mesi di osservazioni dello Z-Spread

Di conseguenza, per ogni obbligazione le prime k osservazioni (dove k dipende dalla finestra massima richiesta) non possono avere tutte le features calcolabili. La strategia adottata è rimuovere iterativamente le righe iniziali fino a quando la prima osservazione presenta tutte le features complete, garantendo che le sequenze LSTM abbiano accesso a feature valide sin dall'inizio della serie utilizzabile.

Implicazioni: La rimozione dei NaN iniziali comporta la perdita dei primi 5 mesi (in media) per ogni bond, sacrificando una piccola percentuale delle righe per garantire qualità delle restanti ed evitare NaN propagation durante il training LSTM. Questa operazione è quindi un trade-off necessario: sacrificare una piccola percentuale delle righe per garantire qualità delle restanti.

Il dataset costruito, dopo tutte le fasi di preprocessing e gestione dei valori mancanti, è stato serializzato come dataframe pandas e costituisce l'input per le fasi successive di feature selection, split temporale e training del modello LSTM descritte nei capitoli seguenti.

7 Features Selection & Preprocessing

7.1 Filtri di Qualità sul Dataset

Dopo le operazioni di ottimizzazione, un filtro stringente per garantire che il dataset finale contenga solo obbligazioni con copertura dati sufficiente e coerenza temporale.

Copertura Temporale

Per ciascuna obbligazione, ogni singola feature deve presentare almeno l'85% di osservazioni non-NaN nella serie temporale.

$$\text{Copertura}_{i,f} = \frac{\text{Osservazioni valide per ISIN } i \text{ e feature } f}{\text{Osservazioni teoriche per ISIN } i} \geq 0.85 \quad \forall f \in \text{Features} \quad (7.1)$$

Con 187 date mensili disponibili, questo richiede un minimo di $\lceil 0.85 \times 187 \rceil = 159$ osservazioni valide per ciascuna delle features selezionate.

Motivazione: Idealmente un LSTM richiede completezza al 100% delle osservazioni, tuttavia con tale vincolo il numero di obbligazioni disponibili risultava insufficiente per costruire un dataset utilizzabile. Il threshold dell'85% rappresenta l'unico e miglior compromesso empirico tra qualità delle serie temporali e numerosità del campione finale. Valori inferiori introdurrebbero eccessiva frammentazione nelle sequenze LSTM; valori superiori ridurrebbero drasticamente la dimensione del dataset già esiguo, fino ad azzerarlo completamente.

Risultati del Filtraggio

Dataset finale:

- 439 obbligazioni uniche
- 28,383 osservazioni bond-mese totali
- Copertura media: 138 osservazioni/bond (11.5 anni)

La drastica riduzione a 439 obbligazioni evidenzia la severità dei vincoli di qualità imposti, in particolare la copertura temporale insufficiente dei prezzi e delle variabili da essi derivate.

7.2 Features Selection: Approccio Theory-Driven

Motivazione Metodologica

La selezione delle features rappresenta uno dei passaggi più critici nella costruzione di modelli predittivi, particolarmente in contesti finanziari caratterizzati da alta dimensionalità e limitata disponibilità di osservazioni. Sebbene esistano metodologie automatiche per la selezione (Recursive Feature Elimination, grid-search, ottimizzazione bayesiana ¹), questo lavoro adotta un approccio **theory-driven** per le seguenti motivazioni:

¹Il codice per Selezione automatica delle features con RFE o metodo bayesiano e per Hyperparameter Tuning automatico con grid search o metodo bayesiano è disponibile nei notebook python per estensioni future.

1. **Interpretabilità Economica:** Ogni feature selezionata ha un fondamento teorico consolidato nella letteratura di factor investing o finanza corporativa. Questo garantisce che i driver predittivi siano economicamente sensati anziché artefatti statistici.
2. **Controllo del Data Mining Bias:** Con un dataset di dimensioni limitate (97,862 osservazioni, 710 bond), procedure data-driven di selezione features rischiano di identificare relazioni spurie ottimizzate in-sample ma non generalizzabili out-of-sample [24]. La selezione theory-driven mitiga questo rischio.
3. **Gestione della Multicollinearità:** La multicollinearità si verifica quando due o più variabili esplicative sono fortemente correlate tra loro. Questa condizione è problematica perché:
 - Rende difficile isolare il contributo individuale di ciascuna feature
 - Aumenta l'instabilità dei pesi del modello (alta varianza dei parametri stimati)
 - Incrementa il rischio di overfitting in presenza di rumore

Nella selezione theory-driven, si è prestata attenzione a evitare l'inclusione simultanea di features ridondanti (es. YTM e Z-Spread sono altamente correlati; si include solo Z-Spread come misura più pura del rischio credito). Variabili che catturano dimensioni distinte del rischio sono state privilegiate.

4. **Robustezza Out-of-Sample:** Features selezionate su base teorica tendono a essere stabili attraverso diversi regimi di mercato, poiché non sono "fitted" alle peculiarità del training set ma riflettono relazioni economiche persistenti.

Ratio Finanziari vs. Valori Assoluti

A partire dalle metriche grezze di bilancio (Total Assets, Total Debt, EBIT, Revenue, ecc.), sono stati calcolati ratio finanziari per l'analisi fondamentale. L'utilizzo di metriche derivate anziché valori assoluti è motivato da:

1. **Normalizzazione Cross-Sectional:** I ratio permettono di confrontare emittenti di dimensioni diverse su una scala comune. Un'azienda con \$10B di debt e \$50B di assets ha la stessa leva (20%) di un'azienda con \$1B di debt e \$5B di assets. I valori assoluti non consentirebbero questa comparabilità.
2. **Interpretabilità Economica:** Ogni ratio ha un significato finanziario diretto consolidato nella pratica professionale (es. Debt/Assets misura leva, EBIT/Interessi misura copertura, ROA misura profittabilità). I valori assoluti in milioni di dollari sono invece difficili da interpretare senza contesto.
3. **Stazionarietà Statistica:** I ratio tendono ad essere più stazionari rispetto ai valori assoluti, che crescono tendenzialmente con l'inflazione e l'espansione aziendale. La stazionarietà facilita la modellazione LSTM riducendo il problema di distribution shift temporale.

Questa scelta è coerente con la letteratura sul credit scoring e factor investing in fixed income [25], [26].

Le 14 Features Finali

Il modello LSTM utilizza 14 features organizzate in tre categorie:

- **Bond-Specific** (5 features): Clean Price, Z-Spread, Modified Duration, Coupon Rate, Time to Maturity — catturano le caratteristiche intrinseche dello strumento e la sua sensibilità al rischio di tasso
- **Bond Factors** (3 features): Momentum 1M, Momentum 6M, Volatility 6M — iden-

tificano pattern di mercato, comportamenti di prezzo recenti e volatilità del rischio creditizio

- **Fundamental Ratios** (7 features): Debt/Assets, EBIT/Interest Expense, ROA, Current Ratio, Operating Cash Flow/Total Debt, EBITDA Margin, Asset Turnover — rappresentano la solidità fondamentale dell'emittente derivata dai bilanci aziendali

La Tabella 7.1 fornisce la descrizione dettagliata di ciascuna feature.

Breakdown Tabellare

Cluster	Variabile	Descrizione
Bond Specific	Clean Price	Prezzo di mercato (corso secco)
	Z-Spread	Spread creditizio costante sopra curva risk-free
	Modified Duration	Sensibilità del prezzo ai tassi d'interesse
	Coupon Rate	Tasso cedolare facciale annuale
	Time to Maturity	Anni residui alla scadenza
Bond Factors	Momentum 0-1m	Rendimento logaritmico t vs $t - 1$
	Momentum 1-3m	Rendimento logaritmico $t - 1$ vs $t - 3$
	Spread Volatility	Deviazione standard rolling (12m) Z-Spread
Fundamentals	Debt/Assets	Leva finanziaria (Total Debt / Total Assets)
	EBIT/Interest	Copertura interessi (Interest Coverage Ratio)
	ROA	Return on Assets (Net Income / Total Assets)
	Working Cap/Assets	Liquidità operativa
	Operating Margin	Efficienza operativa (EBIT / Revenue)
	Cash/Assets	Solidità di cassa

Tabella 7.1: Dettaglio delle 14 features utilizzate nel modello finale

7.3 Definizione del Target Predittivo

Il target predittivo utilizzato in questo lavoro è il **rendimento logaritmico** del prezzo clean a un mese:

$$y_{t+1} = \log(P_{t+1}^{\text{clean}}) - \log(P_t^{\text{clean}}) \quad (7.2)$$

Questa scelta è motivata principalmente dalla proprietà di **additività temporale** dei log-rendimenti, non presente per i rendimenti vanilla.

$$r_{t \rightarrow t+n} = \sum_{i=0}^{n-1} r_{t+i} \quad (7.3)$$

Questo semplifica l'analisi cumulata delle performance e la costruzione di strategie multi-periodo. Per rendimenti semplici, l'aggregazione richiede prodotti composti, meno trattabili analiticamente.

Nota sul Prezzo Clean vs. Dirty

Il target è calcolato sul **prezzo clean** (escludendo il rateo) anziché sul prezzo dirty (incluso il rateo) per isolare le variazioni di valore di mercato da quelle deterministiche dovute al maturare della cedola. Il rateo cresce linearmente tra due date di pagamento cedolare, introducendo un trend prevedibile che "contaminerebbe" il target. Utilizzare il prezzo clean garantisce che y_{t+1} catturi solo le variazioni di valutazione di mercato (spread movements, rate movements).

7.4 Normalizzazione

Prima di procedere con il training del modello LSTM, le features selezionate devono essere sottoposte a normalizzazione per garantire convergenza stabile e performance ottimali della rete neurale.

Motivazione

Le features selezionate presentano scale eterogenee (Prezzo: 80-120, Z-Spread: 0.01-0.10, Duration: 2-15, Ratio: 0.5-20+). Senza normalizzazione, features con valori grandi dominerebbero il gradiente, rallentando la convergenza e introducendo instabilità numerica.

Metodologia: StandardScaler

È stato utilizzato `StandardScaler` di scikit-learn, che standardizza ciascuna feature sottraendo la media e dividendo per la deviazione standard:

$$X_{\text{norm}} = \frac{X - \mu_{\text{train}}}{\sigma_{\text{train}}} \quad (7.4)$$

dove μ_{train} e σ_{train} sono calcolati **esclusivamente sul training set** (`.fit()` solo su training). Le trasformazioni (`.transform()`) vengono applicate sia al training che al test set usando gli stessi parametri del training, evitando data leakage.

Normalizzazione del Target

Anche il target y (log-rendimenti) è stato normalizzato separatamente:

$$y_{\text{norm}} = \frac{y - \mu_{y,\text{train}}}{\sigma_{y,\text{train}}} \quad (7.5)$$

Dopo il training, le predizioni del modello (in spazio normalizzato) vengono riportate in spazio originale tramite inversione:

$$\hat{y}_{\text{original}} = \hat{y}_{\text{norm}} \cdot \sigma_{y,\text{train}} + \mu_{y,\text{train}} \quad (7.6)$$

7.5 Split Temporale e Validazione

Divisione Basata sul Tempo

Una divisione del dataset per ISIN (es. 70% dei bond per training, 30% per testing) introdurrebbe **data leakage temporale**: il modello, addestrato su bond A nel periodo 2010-2022, verrebbe testato su bond B nello stesso periodo. Sebbene i bond siano diversi, le informazioni temporali sono sovrapposte, consentendo al modello di apprendere pattern di mercato piuttosto che relazioni causali bond-specifiche.

Per questa ragione, la divisione deve essere basata sul **tempo, non sul cross-section**, simulando accuratamente uno scenario di trading forward-looking.

Bilanciamento della Composizione Cross-Sectional

Dopo la divisione temporale, i sottocampioni presentano distribuzioni eterogenee rispetto a dimensioni strutturali chiave (valuta, paese, scadenza, tipologia cedolare). Uno sbilanciamento severo compromette la validità out-of-sample per distribution shift (il modello apprende su un dominio non generalizzabile) e selection bias (performance riflettono la composizione specifica del test set anziché capacità predittive generalizzabili).

Per mitigare questo rischio, è stata applicata una procedura iterativa di rimozione selettiva di bond "sbilanciati", con l'obiettivo di far convergere le distribuzioni di training e test verso la distribuzione target (l'intero dataset). Le dimensioni considerate sono:

- **Coupon Category:** Fixed-rate, Floating-rate, Zero-coupon
- **Currency:** EUR, USD, GBP, CHF, altre
- **Country:** Paese dell'emittente (UK, Germania, Francia, ecc.)
- **Duration Bucket:** Scadenza residua raggruppata in fasce (1-3y, 3-5y, 5-7y, 7-10y, 10-15y, >15y)

L'algoritmo calcola uno score di sbilanciamento come somma delle deviazioni assolute tra proporzioni correnti e target:

$$\text{Score}_S = \sum_{d \in \text{Dimensions}} \sum_{c \in \text{Categories}_d} |p_{S,d,c} - p_{\text{target},d,c}| \quad (7.7)$$

dove $p_{S,d,c}$ è la proporzione della categoria c nella dimensione d per il sottocampione S . Ad ogni iterazione si rimuove il bond che massimizza il miglioramento dello score, arrestandosi quando: (i) lo score scende sotto soglia (0.02 per dimensione), (ii) si raggiunge il limite di rimozioni (20% del campione), o (iii) nessuna rimozione migliora lo score (early stopping dopo 10 tentativi).

Risultati: Training set: 58 bond rimossi (11.3%), 232 finali, convergenza raggiunta. Test set: 4 bond rimossi (19.6%), 407 finali, convergenza raggiunta.

Scelta della Proporzione

Il dataset è stato diviso temporalmente utilizzando gennaio 2021 come data di cutoff: tutte le osservazioni pre-2021 costituiscono il training set, quelle dal 2021 in poi il validation/test set. Questa scelta bilancia tre esigenze:

- **Training set ampio:** 127 mesi (gennaio 2011 - dicembre 2020) garantiscono un numero sufficiente di sequenze per l'addestramento del modello LSTM
- **Test set rappresentativo:** 54 mesi (gennaio 2021 - settembre 2025) coprono regimi di mercato eterogenei: ripresa post-COVID, ciclo rialzo tassi BCE, inflazione elevata e normalizzazione monetaria
- **Densità temporale bilanciata:** La disponibilità di obbligazioni aumenta progressivamente verso date più recenti (espansione del mercato corporate europeo post-crisi e maggiore copertura dei database). Lo split al 2021 mitiga lo sbilanciamento, evitando un test set eccessivamente concentrato su pochi bond (split più tardivo) o eccessivamente piccolo (split più anticipato)

8 Implementazione del Modello

Questo capitolo descrive l'implementazione tecnica del modello LSTM, dalla definizione dell'architettura neurale alle procedure di training e validazione. L'approccio seguito privilegia la parsimonia strutturale e la robustezza metodologica, riflettendo i vincoli imposti dalla dimensione limitata del dataset.

8.0.1 Costruzione delle Sequenze

Dopo preprocessing e split temporale, le sequenze LSTM vengono costruite con:

- **Lookback window:** 6 mesi di storia per ciascuna sequenza; scelta presa nell'ottica di un dataset particolarmente esiguo, per ridurre la complessità del modello (vedi Capitolo 8).
- **Step size:** 1 mese
- **Target:** Rendimento logaritmico al mese successivo
- **Formato input:** Tensor 3D di dimensione $(n_sequences, 6, 15)$

Il dataset preprocessato costituisce l'input per la fase di implementazione e training del modello.

8.1 Architettura del Modello LSTM

Principi di Design

Con un dataset finale di 439 obbligazioni e 30,587 sequenze di training, la scelta di un'architettura LSTM parsimoniosa non rappresenta una limitazione, bensì una necessità metodologica. Il principio del rasoio di Occam—scegliere il modello più semplice compatibile con i dati—guida la progettazione dell'architettura per mitigare il rischio di overfitting in contesti data-scarce [19].

Struttura dei Layer

L'architettura implementata segue una configurazione sequenziale a quattro layer:

Input Layer

Accetta sequenze multidimensionali di forma $(T \times F)$, dove:

- $T = 6$ mesi: lookback window che definisce la memoria temporale del modello
- $F = 14$: numero di features theory-driven selezionate (Capitolo 7)

La finestra temporale di 6 mesi bilancia capacità di cattura dei cicli di credito (trend tipicamente semestrali [6]) e contenimento della complessità (ogni mese incrementa linearmente i parametri LSTM).

LSTM Layer

Singolo strato ricorrente con 30 unità neuronali e funzione di attivazione tanh.

I valori ottimali di unità neuronali, secondo la letteratura, oscillano tra 50 e 100, ma le dimensioni del dataset in termini di osservazioni a disposizione impongono una restrizione

a 30; soglia considerata essenziale, per la quale configurazioni <30 unità sono insufficienti per pattern temporali complessi.

L'attivazione tanh è intrinseca all'architettura LSTM standard, normalizzando output e stati interni nell'intervallo $[-1, +1]$. Questa normalizzazione facilita il flusso stabile dei gradienti durante la backpropagation through time (BPTT), mitigando il problema del vanishing gradient che affliggeva le RNN tradizionali [10].

Dropout Layer

Dropout con rate 30%, applicato immediatamente dopo il layer LSTM.

Il dropout [18] è una tecnica di regolarizzazione che disattiva casualmente il 30% dei neuroni durante ogni forward pass nel training, forzando la rete a sviluppare rappresentazioni ridondanti e prevenendo co-adattamento, riducendo il rischio di overfitting. Il rate aggressivo (30% vs. 20% standard) è giustificato dal dataset piccolo (5,751 sequenze vs. centinaia di migliaia equity), alta dimensionalità relativa (90 valori/sequenza) e rumore finanziario elevato [2].

Dense Hidden Layer

Strato fully-connected con 15 unità e attivazione ReLU.

Conteggio parametri:

$$\text{Parametri}_{\text{Dense}} = (30 + 1) \times 15 = 465 \quad (8.1)$$

dove 30 è il numero di input provenienti dal layer LSTM, il +1 rappresenta il bias, e 15 è il numero di neuroni nell'hidden layer.

Questo layer apprende trasformazioni non-lineari delle rappresentazioni LSTM. La scelta di 15 unità (rapporto 2:1 rispetto LSTM) permette una riduzione dimensionale progressiva e parsimonia parametrica; mentre la funzione di attivazione ReLU introduce non linearità e mitiga il vanishing gradient, scelta standard per gli hidden layers.

Output Layer

Strato fully-connected finale con 1 unità e attivazione lineare.

Conteggio parametri:

$$\text{Parametri}_{\text{Output}} = (15 + 1) \times 1 = 16 \quad (8.2)$$

Questo layer proietta le 15 rappresentazioni finali in una singola predizione scalare: il rendimento logaritmico atteso al mese $t + 1$. L'attivazione lineare è necessaria per problemi di regressione dove il target può assumere valori arbitrari (non bounded). In contrasto, problemi di classificazione userebbero sigmoid (binaria) o softmax (multiclasse).

8.2 Loss Function e Ottimizzatore

Loss Function: Mean Squared Error (MSE)

La funzione obiettivo minimizzata durante il training è l'Errore Quadratico Medio tra il rendimento logaritmico previsto $\hat{y}_{t+1}$ e quello effettivamente realizzato y_{t+1} :

$$\text{Loss} = \text{MSE}(\hat{y}, y) = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 \quad (8.3)$$

dove $y_{t+1} = \log(P_{t+1}^{\text{clean}}) - \log(P_t^{\text{clean}})$ come definito nel Capitolo 7, Sezione 7.3.

Motivazione della scelta:

L'MSE è la loss function standard per problemi di regressione continua in deep learning e rappresenta una scelta consolidata in letteratura (default in TensorFlow/Keras). Tre proprietà la rendono particolarmente adatta per rendimenti finanziari:

1. **Penalizzazione quadratica:** Errori grandi sono penalizzati più che proporzionalmente rispetto a errori piccoli. Un errore di 10 bp ha penalità 100 volte maggiore di un errore di 1 bp. Questa proprietà è desiderabile in finanza: large misses hanno conseguenze sproporzionate per la gestione del rischio.
2. **Differenziabilità ovunque:** L'MSE è derivabile in ogni punto, garantendo gradienti ben definiti per l'ottimizzazione. Loss function alternative come MAE (Mean Absolute Error) presentano discontinuità nella derivata in zero, complicando l'ottimizzazione con gradient descent.
3. **Compatibilità con distribuzione log-rendimenti:** Log-rendimenti sono approssimativamente simmetrici attorno a zero (come discusso nel Capitolo 7). L'MSE assume implicitamente residui simmetrici, rendendola ben calibrata per questo target.
4. **Convergenza con la letteratura:** Studi precedenti su modelli ML per bond (Feng et al. 2025 [27], Gu et al. 2020 [1]) utilizzano MSE come loss function standard, facilitando il confronto diretto delle performance.

Ottimizzatore: Adam

L'algoritmo di ottimizzazione utilizzato è **Adam** (Adaptive Moment Estimation) [13] con learning rate $\alpha = 0.001$, come discusso nel Capitolo 3 (Sez. 4.3). La scelta di Adam è motivata dalla sua robustezza su dati finanziari rumorosi e dalla convergenza veloce in contesti data-scarce, mentre il learning rate di 0.001 rappresenta il default empiricamente consolidato.

8.3 Procedura di Training

Ciclo di Training

Il processo di training segue un ciclo iterativo (già presentato al Capitolo 4.3) che si ripete per ogni batch in ogni epoca:

1. **Forward Pass:** Le sequenze di input del batch vengono propagate attraverso la rete layer-by-layer, generando predizioni.
2. **Calcolo Loss:** L'MSE tra predizioni e target effettivi del batch viene calcolato.
3. **Backward Pass (Backpropagation Through Time):** L'errore viene propagato all'indietro attraverso i layer, calcolando il gradiente $\partial \text{Loss} / \partial \theta_i$ per ciascun parametro θ_i . Per LSTM, la backpropagation avviene anche attraverso i timestep temporali (BPTT), permettendo di apprendere dipendenze a lungo termine.
4. **Weight Update:** L'ottimizzatore Adam modifica i parametri nella direzione che riduce l'errore:

$$\theta_{t+1} = \theta_t - \alpha \cdot \text{Adam_adjustment}(\nabla_{\theta} \text{Loss}) \quad (8.4)$$

dove Adam_adjustment incorpora momentum e learning rate adattivo per ogni parametro.

Questo ciclo si ripete per tutti i batch nell'epoca, e l'epoca stessa si ripete fino a convergenza o intervento dell'early stopping.

Configurazione dei Parametri di Training

Batch Size: 32

Un batch è un sottoinsieme di sequenze processate simultaneamente durante un'iterazione di training. La scelta di 32 è uno standard empirico consolidato in deep learning [28], considerato particolarmente robusto.

Massimo Epoche: 100

Un'epoca corrisponde a un passaggio completo attraverso l'intero training set.

Il limite massimo di 100 epoche è conservativo: nella pratica, l'early stopping (discusso nella Sezione 8.3) interrompe il training molto prima. Il valore elevato garantisce che il modello abbia budget sufficiente per convergere anche in scenari difficili.

Validation Split: 15%

Il 15% del training set è riservato come **validation set interno**, utilizzato esclusivamente per monitorare l'early stopping, distinto dal test set out-of-sample.

La validation loss (MSE calcolato sul validation set interno) guida l'early stopping. Se la validation loss smette di migliorare, significa che il modello sta iniziando a overfittare sul training set e l'apprendimento deve essere interrotto.

Early Stopping

L'early stopping è una tecnica di regolarizzazione che identifica il punto ottimale di arresto del training prima che il modello inizi a memorizzare rumore [12].

Meccanismo

L'algoritmo monitora la validation loss ad ogni epoca. Se la validation loss non migliora per un numero consecutivo di epoche (definito dal parametro **patience**), il training viene interrotto e i pesi del modello vengono ripristinati al miglior checkpoint osservato.

Configurazione: `patience = 10 epoche`

Questo significa:

1. Ad ogni epoca, calcola validation loss
2. Se $\text{validation loss} < \text{miglior validation loss precedente}$: aggiorna miglior checkpoint, reset contatore patience
3. Se $\text{validation loss} \geq \text{miglior validation loss precedente}$: incrementa contatore patience
4. Se contatore patience = 10: interrompi training, ripristina pesi al miglior checkpoint

Motivazione per `patience = 10`

La scelta di 10 epoche consecutive senza miglioramento bilancia due rischi:

- **Patience troppo bassa** (es. 3-5): Rischio di arresto prematuro. La validation loss può oscillare naturalmente per alcune epoche prima di riprendere a scendere. Interrompere troppo presto limita l'apprendimento.
- **Patience troppo alta** (es. 20-30): Rischio di overfitting tardivo. Dopo 15-20 epoche senza miglioramento, è altamente probabile che il modello stia già overfittando. Attendere ulteriormente spreca tempo computazionale senza guadagni.

Patience = 10 è un compromesso robusto, particolarmente appropriato per dataset finanziari rumorosi dove la validation loss può presentare oscillazioni di breve periodo.

Critico per Dataset Piccoli

L'early stopping è cruciale in contesti le sequenze di training disponibili sono molto basse, il rischio che il modello "memorizzi" specifici pattern del training set anziché estrarre regolarità generalizzabili è elevato. Senza early stopping, il modello continuerebbe a ridurre la training loss indefinitamente (convergendo verso zero), ma la performance out-of-sample peggiorerebbe progressivamente.

8.4 Riepilogo Configurazione

La Tabella 8.1 riassume tutti i parametri architetturali e di training del modello finale.

Tabella 8.1: Configurazione completa del modello LSTM

Parametro	Valore
Architettura	
Input Shape	(6 mesi, 14 features)
LSTM Units	30
LSTM Activation	tanh (intrinseco)
Dropout Rate (post-LSTM)	30%
Dense Hidden Units	15
Dense Hidden Activation	ReLU
Dropout Rate (post-Dense)	30%
Output Units	1
Output Activation	Lineare
Prediction Horizon	1 mese
Parametri Totali	15,774
Training	
Optimizer	Adam
Learning Rate	0.001
Loss Function	Mean Squared Error
Batch Size	32
Max Epochs	100
Early Stopping Patience	10 epoche
Validation Split	15% del training set

8.5 Strategia di Trading Long-Short

A valle delle predizioni del modello, viene simulata una strategia di investimento sistematica di tipo **market-neutral long-short** basata su ranking per quintili. La logica di questa scelta e le motivazioni teoriche sono state discusse nel Capitolo 4 (Sez. 4.3).

Costruzione del Portafoglio

Alla fine di ogni mese t , il portafoglio viene costruito secondo la seguente procedura:

1. **Generazione predizioni:** Il modello LSTM genera una predizione di rendimento atteso $\hat{y}_{t+1}$ per tutti i bond nell'universo out-of-sample disponibili al mese t .

2. **Ranking:** I bond vengono ordinati in ordine decrescente per rendimento atteso predetto: $\hat{y}_1 \geq \hat{y}_2 \geq \dots \geq \hat{y}_N$.
3. **Assegnazione quintili:** I bond vengono suddivisi in quintili sulla base del loro ranking (Q1 = top 20%, Q5 = bottom 20%).
4. **Condizionalità dello short:** Il leg short viene implementato solo se la predizione media del quintile Q5 è negativa:

$$\text{Short Q5} \iff \frac{1}{|Q5|} \sum_{j \in Q5} \hat{y}_j < 0 \quad (8.5)$$

Questa condizione evita di shortare bond che il modello prevede in performance positiva, riducendo il rischio di perdite dallo short in mercati con strong positive drift. Se la condizione non è soddisfatta, la strategia opera solo long (Q1).

5. **Position sizing:** Tutte le obbligazioni scambiate (sia long che short, se presenti) sono equally-weighted sul portafoglio complessivo:

$$w_i = \frac{1}{|Q1| + |Q5_{\text{active}}|} \quad (8.6)$$

dove $|Q5_{\text{active}}|$ è il numero di bond shortati (uguale a $|Q5|$ se la condizione è soddisfatta, 0 altrimenti). Questo garantisce che ogni bond abbia lo stesso peso assoluto indipendentemente dal leg di appartenenza.

6. **Calcolo rendimento mensile:** Il rendimento netto della strategia long-short per il mese $t + 1$ è:

$$R_{t+1}^{\text{LS}} = \sum_{i \in Q1} w_i \cdot r_{i,t+1} - \sum_{j \in Q5_{\text{active}}} w_j \cdot r_{j,t+1} \quad (8.7)$$

dove $r_{i,t+1} = \exp(y_{i,t+1}) - 1$ è il rendimento percentuale realizzato dal bond i nel mese $t + 1$, e $y_{i,t+1}$ è il corrispondente log-rendimento.

Rebalancing Mensile

Alla fine di ogni mese, il portafoglio viene completamente ribilanciato ripetendo la procedura di costruzione descritta sopra: generazione predizioni, ranking, assegnazione quintili, valutazione condizionalità short, e position sizing. Questo garantisce che la strategia sia sempre allineata alle predizioni più aggiornate del modello.

Il rebalancing mensile comporta diverse implicazioni operative:

- **Turnover elevato:** Potenzialmente 100% mensile se i quintili cambiano completamente. Nella pratica, il turnover è inferiore (40-60%) grazie a persistenza parziale nel ranking.
- **Costi di transazione impliciti:** Ogni transazione (buy/sell) comporta bid-ask spread e potenziale market impact. Questi costi non sono inclusi nella simulazione baseline ma sono discussi come limitazione operativa nel Capitolo 9.
- **Short selling e disponibilità titoli:** La strategia assume disponibilità continua di titoli da prendere in prestito per le posizioni short. In pratica, la disponibilità di bond corporate per short selling può essere limitata, particolarmente per emissioni meno liquide o in periodi di stress di mercato.
- **Sovraesposizione durante inversioni di mercato:** La condizionalità dello short (attivato solo se $\hat{y}_{Q5} < 0$) riduce l'esposizione netta in fasi di mercato bullish generalizzato. Tuttavia, durante inversioni di tendenza (passaggio da mercato rialzista a

ribassista), la strategia può trovarsi temporaneamente sovraesposta al rischio di mercato se il modello non anticipa rapidamente il cambio di regime. In questi periodi di transizione, mantenere la gamba short anche a costo di un leggero peggioramento dell'average return potrebbe fornire copertura contro movimenti avversi generalizzati, riducendo il rischio di drawdown severi. Questa considerazione rappresenta un trade-off tra massimizzazione del rendimento atteso e controllo del rischio di coda.

Periodo di Simulazione

La strategia viene simulata esclusivamente sul periodo out-of-sample: gennaio 2021 - settembre 2025 (54 mesi). Questo garantisce che nessuna informazione dal periodo di test è stata utilizzata durante il training, quindi che la performance misurata rifletta genuina capacità predittiva forward-looking, rendendo i risultati comparabili a uno scenario di trading. I risultati quantitativi della strategia (rendimento cumulato, Sharpe ratio, maximum drawdown, Information Coefficient) sono presentati e discussi nel Capitolo 9.

9 Risultati e Discussione

Questo capitolo presenta i risultati empirici del modello LSTM applicato al dataset out-of-sample (gennaio 2021 - settembre 2025, 54 mesi) e discute le implicazioni per la pratica del factor investing in bond europei.

9.1 Performance Predittiva Out-of-Sample

Metriche Statistiche

Tabella 9.1: Metriche di previsione out-of-sample del modello LSTM

Metrica	Valore	Interpretazione
Information Coefficient (IC)	0.3564	Correlazione predizioni-realizzi
p-value IC	< 0.0001	Statisticamente significativo
R^2	0.1574	15.74% varianza spiegata
Hit Rate	56.06%	Direzione corretta
MAE	0.0175	Errore medio assoluto
RMSE	0.0348	Root Mean Squared Error

Analisi dell'Information Coefficient

L'**Information Coefficient** (IC), definito nel Capitolo 3 (Sez. 4.4) come la correlazione di Spearman tra ranking predetto e ranking realizzato dei rendimenti, è la metrica centrale per strategie cross-sectional basate su ranking. Il modello LSTM ottiene un IC out-of-sample di **0.3564**.

La significatività statistica è stata verificata mediante test t sulla correlazione, ottenendo p-value < 0.0001 . Questo esclude che il risultato sia attribuibile a fluttuazioni casuali.

Contestualizzazione critica rispetto alla letteratura: Un IC di 0.3564 è inusualmente elevato rispetto ai benchmark documentati in letteratura. Per contestualizzare questo risultato:

- **Gu et al. (2020):** Su equity USA con dataset massicci (S&P 1500, 30 anni), architetture ML complesse ottengono $IC \approx 0.05 - 0.15$, con mediana intorno a 0.10. Neural network sofisticate raggiungono IC massimo $\approx 0.12 - 0.15$.
- **Feng et al. (2025):** Su corporate bond USA con reti neurali applicate a factor investing, IC documentati sono nell'intervallo $0.15 - 0.20$, significativamente superiori all'equity grazie a maggiore persistenza degli spread creditizi.
- **Grinold-Kahn (1999):** Nel framework classico di asset management quantitativo, $IC > 0.10$ sono già considerati indicativi di skill predittivo significativo; $IC > 0.20$ sono rari e associati a strategie altamente profittevoli.

Interpretazione: Il nostro valore è **multiple volte superiore** ai benchmark letteratura per corporate bond USA e significativamente superiore ai valori tipici per equity. Un IC di 0.3564 richiede interpretazione cauta. Per questo sono stati individuate quattro considerazioni fondamentali non mutualmente esclusive:

1. **Inefficienze residue mercato europeo:** Il mercato corporate EUR, meno coperto da analisti e con minore presenza di hedge fund quantitativi rispetto al mercato USA, potrebbe presentare inefficienze maggiori sfruttabili da approcci sistematici. Il set informativo delle 14 features (discusse nel Capitolo 7), che integra spread, duration, momentum e fundamentals in modo mirato ai driver economici del credito, combinato con la capacità del modello LSTM di catturare non-linearità, potrebbe estrarre queste inefficienze residue meno arbitraggiate rispetto al mercato USA.
2. **Quality bias del campione:** I filtri di qualità applicati selezionano bond di emittenti grandi, trasparenti e liquidi. Su questo sottoinsieme "high-quality", i segnali fondamentali (leverage, profittabilità, coverage) sono più informativi rispetto a un universo che include emittenti opachi o distressed. L'IC su un campione rappresentativo dell'intero mercato corporate EUR sarebbe probabilmente inferiore.
3. **Periodo di test favorevole:** Il test set di 54 mesi (gennaio 2021 - settembre 2025) copre molteplici regimi di mercato (ripresa post-COVID, ciclo rialzo tassi BCE) e fornisce una valutazione più robusta rispetto a test brevi, ma non include eventi di tail risk estremo paragonabili a marzo 2020 o 2008-2009. In periodi di stress sistemico, l'IC tipicamente degrada significativamente.
4. **Rapporto parametri/osservazioni sotto soglia ottimale:** Il modello LSTM presenta 6,001 parametri totali addestrati su 33,746 osservazioni (sequenze training), risultando in un rapporto di 5.62 osservazioni per parametro. La letteratura statistica raccomanda rapporti minimi di 10:1 per garantire generalizzazione robusta; applicazioni industriali di ML mirano a 50:1 o superiori. Il rapporto di 5.62, pur mitigato da regolarizzazione aggressiva (dropout 30%, early stopping), si colloca al di sotto delle best practice e aumenta la probabilità che l'IC elevato rifletta parzialmente overfitting su pattern idiosincratici del training set anziché skill predittivo puro generalizzabile.
5. **Look-ahead bias sui dati fondamentali:** Come discusso nel Capitolo 5, i ratio finanziari derivati dai bilanci annuali sono stati propagati (forward fill) per 12 mesi senza incorporare i ritardi di pubblicazione tipici (2-4 mesi). Questo introduce informazione futura nelle features fondamentali, sovrastimando leggermente la capacità predittiva effettivamente implementabile.

Altre Metriche di Previsione

$R^2 = 0.1574$: Il modello spiega il 15.74% della varianza nei rendimenti futuri. Come discusso nel Capitolo 3 (Sez. 4.4), nei mercati finanziari dove il rumore domina il segnale, R^2 tra 0.10-0.30 sono considerati eccellenti. Per contestualizzare: Gu et al. (2020) [1] riportano R^2 di 0.05-0.15 su equity USA con modelli ML complessi; Feng et al. (2025) [27] documentano R^2 di 0.15-0.25 su corporate bond USA. Il nostro valore di 0.1574 si trova in linea alla letteratura, coerente con l'applicazione di LSTM a un campione quality-selected.

Hit Rate = 56.06%: Il modello prevede correttamente la direzione del rendimento (positivo/negativo) dei titoli in ingresso. Un hit rate random sarebbe 50%; il 56% dell'esperimento indica skill predittivo.

MAE e RMSE: L'errore medio assoluto (1.75%) e la radice dell'errore quadratico medio (3.48%) quantificano la deviazione tipica delle predizioni dai valori realizzati. Questi valori sono comparabili con le volatilità mensili tipiche dei bond corporate, suggerendo che le predizioni sono calibrate ragionevolmente.

9.2 Performance della Strategia Long-Short

Risultati Aggregati

La Tabella 9.2 riassume le metriche finanziarie della strategia long-short basata su quintili (descritta nel Capitolo 8).

Tabella 9.2: Performance della strategia long-short out-of-sample

Metrica	Valore
Rendimento Totale	118.14%
Rendimento Annualizzato	18.93%
Volatilità Annualizzata	5.55%
Sharpe Ratio	2.89
Maximum Drawdown	-0.95%
Win Rate (mesi positivi)	77.78% (42/54 mesi)

Analisi dello Sharpe Ratio

Lo **Sharpe Ratio**, come discusso nel Capitolo 3 (Sez. 4.4), misura il rapporto tra rendimento in eccesso e volatilità. Per strategie mensili, viene annualizzato moltiplicando per $\sqrt{12}$:

$$\text{Sharpe Ratio} = \frac{\bar{R}_p - R_f}{\sigma_p} \times \sqrt{12} \quad (9.1)$$

dove $\bar{R}_p$ è il rendimento medio mensile del portafoglio, R_f il tasso risk-free (approssimato con rendimento ECB AAA a breve termine, media $\approx 1.53\%$ annuo durante il periodo 2021-2025) e σ_p la volatilità mensile.

Sharpe Ratio Gross

La simulazione baseline, assumendo esecuzione istantanea ai prezzi di chiusura senza frizioni operative, produce uno **Sharpe Ratio gross annualizzato di 2.89**. Questo valore supera i benchmark documentati in letteratura: Feng et al. (2025) [27] riportano Sharpe Ratio gross fino a 2.40 per strategie neural network su corporate USA.

Nella scala di valutazione standard: Sharpe > 1.0 è considerato buono, > 2.0 eccellente, > 3.0 straordinario. Il valore di 2.89 si colloca nella fascia superiore, prossimo alla soglia di eccellenza massima.

Cautele operative: Il valore di 2.89 rappresenta un upper bound teorico ottenuto assumendo esecuzione ideale senza costi di transazione, slippage e frizioni operative tipiche del mercato OTC su corporate bond. In particolare, la strategia long-short assume la possibilità di vendere allo scoperto obbligazioni corporate europee, operazione che nella pratica risulta estremamente costosa (borrow fees tipicamente 25-100 bps annui, fino a 200-500 bps per titoli illiquidi) e spesso non disponibile per gran parte dell'universo investibile, data la frammentazione del mercato repo europeo e l'accesso limitato al securities lending istituzionale. Dickerson et al. (2024) mostrano che delay/transaction costs riducono drasticamente (fino ad annullare in alcuni casi) la performance di strategie ad alto turnover, portando molti Sharpe gross positivi a valori net zero o bassi. Applicato allo Sharpe Ratio gross risultante dal lavoro, si presume che il Ratio netto diminuisca fino ad allinearsi con valori più conservativi.

Maximum Drawdown e Stabilità

Il **Maximum Drawdown** di -0.95% rappresenta la massima perdita cumulata dal picco al minimo durante il periodo out-of-sample di 54 mesi (gennaio 2021 - settembre 2025). Questo valore estremamente contenuto, inferiore all'1%, richiede interpretazione cauta: un drawdown così ridotto è eccezionale per una strategia attiva e riflette probabilmente la combinazione di un periodo senza eventi di stress estremo (assenza di crisi paragonabili a marzo 2020 o 2008) e assunzioni operative ottimistiche (esecuzione istantanea, liquidità uniforme). Un drawdown realistico in contesti operativi sarebbe nell'ordine del 3-8%, allineato con strategie quantitative bond documentate in letteratura.

Win Rate e Consistenza

Il **Win Rate** del 77.78% (42 mesi positivi su 54) indica che la strategia genera rendimenti positivi in oltre tre quarti dei mesi del periodo out-of-sample. La consistenza mensile è particolarmente rilevante per l'implementabilità operativa: un win rate elevato riduce il rischio di abbandono prematuro della strategia da parte di investitori che potrebbero perdere fiducia dopo sequenze prolungate di perdite. Nel nostro caso, la combinazione di win rate 77.78%, Sharpe Ratio 2.89 e drawdown contenuto suggeriscono che la strategia vince frequentemente e che le vincite superano sistematicamente le perdite in termini risk-adjusted.

9.3 Confronto con Benchmark

Regressione OLS Lineare

Per isolare il contributo dell'architettura LSTM rispetto a un modello lineare baseline, è stata addestrata una regressione OLS multivariata sulle stesse 15 features. La Tabella 9.3 confronta le performance. L'LSTM supera l'OLS su tutte le metriche chiave. La differenza

Tabella 9.3: Confronto LSTM vs. OLS

Metrica	LSTM	OLS
IC out-of-sample	0.3564	0.0940
R^2	0.1574	0.0550
Hit Rate	56.06%	52.92%
Sharpe Ratio (strategia)	2.89	1.83
Rendimento annualizzato	18.93%	17.27%
Volatilità	5.55%	8.10%
Max Drawdown	-0.95%	-7.21%

è particolarmente marcata nell'IC, confermando che la capacità dell'LSTM di modellare:

- **Dipendenze temporali:** L'LSTM cattura momentum, inerzia negli spread, e traiettorie di deterioramento creditizio che l'OLS, essendo memoryless, ignora.
- **Non-linearità:** Le interazioni complesse tra leverage, coverage e rating di mercato (discusse nel Capitolo 3) sono approssimate linearmente dall'OLS, limitandone la capacità predittiva.

Benchmark Passivi (ETF)

Per contestualizzare ulteriormente, la Tabella 9.4 confronta la strategia Long-Short con ETF passivi rappresentativi del mercato corporate europeo Investment Grade sul periodo completo.

Tabella 9.4: Confronto con ETF Corporate EUR IG (gennaio 2021 - settembre 2025)

Metrica	LSTM L/S	iShares Euro Corp (IHYG)	Vanguard EUR Corp (VECA)
Rendimento totale	118.14%	12.66%	-3.34%
Rendimento annuo	18.93%	2.68%	-0.75%
Volatilità	5.55%	7.76%	5.53%
Sharpe Ratio	2.89	0.18	-0.38
Max Drawdown	-0.95%	-16.43%	-16.77%

L'outperformance è marcata su tutto il periodo di 54 mesi. La strategia LSTM L/S dimostra superiorità sia in termini di rendimento, sia di controllo del rischio (Sharpe Ratio, Max Drawdown). Tuttavia, va notato che: (i) gli ETF sono long-only e risentono di fasi di rialzo tassi (2022-2023), mentre la strategia L/S è market-neutral; (ii) la strategia riportata è gross, mentre gli ETF includono TER 0.15-0.20%; (iii) l'universo investibile differisce. Il confronto evidenzia il valore del market-neutral approach in contesti di mercato variabili.

9.4 Discussione e Interpretazione

Contributi dello Studio

Questa tesi fornisce tre contributi principali:

1. **Dataset proprietario integrato:** Costruzione di un dataset che integra prezzi bond (Cbonds), fondamentali (WRDS/Compustat), e tassi risk-free (ECB) per 710 obbligazioni corporate europee su 15 anni. Questo supera la frammentazione tipica dei dati europei.
2. **Validazione empirica LSTM su bond europei:** Dimostrazione che architetture ricorrenti catturano segnali predittivi non accessibili a modelli lineari nel contesto specifico del mercato corporate EUR, meno studiato rispetto al mercato USA.
3. **Evidenza di alpha implementabile:** Anche scontando frizioni operative, i risultati suggeriscono che strategie factor-based guidate da ML possono generare alpha economicamente significativo (Sharpe 1.4-1.7 netto stimato).

Contestualizzazione nella Letteratura

I risultati sono coerenti con la letteratura recente su ML applicato ai mercati fixed income:

- **Feng et al. (2025):** Documentano Sharpe Ratio 1.8-2.4 per neural networks su corporate USA. I nostri risultati sono superiori, suggerendo maggiori inefficienze nel mercato europeo.
- **Gu et al. (2020):** Mostrano che ML cattura non-linearità in equity che OLS ignora. Confermiamo questo pattern in bond, con IC differenziale particolarmente elevato tra LSTM e OLS (0.3564 vs. 0.0940).
- **Dickerson et al. (2024):** Enfatizzano l'importanza di modellare costi e ritardi. I nostri risultati gross rappresentano un upper bound, coerente con la loro metodologia di reporting.

Il valore aggiunto specifico di questo lavoro è l'applicazione al mercato europeo, che presenta sfide uniche (frammentazione giurisdizionale, minore liquidità, scarsità dati) non presenti nel mercato USA.

10 Conclusioni

10.1 Limitazioni e Cautele

Dimensione del dataset e vincoli architettureali: La limitazione più rilevante di questo studio riguarda la scala del dataset rispetto ai requisiti tipici di architetture LSTM. Con 400+ obbligazioni, 15 feature e sequenze di 6 mesi, il dataset risulta significativamente inferiore agli standard documentati in letteratura per deep learning applicato a finanza.

Come discusso nella Sezione 9.1 e nella Sezione 6.6, il rapporto parametri/osservazioni misurato (5.62) si colloca al di sotto della soglia raccomandata dalla letteratura statistica (10:1), confermando il vincolo strutturale che ha richiesto l'uso aggressivo di tecniche di regolarizzazione (dropout 30%, weight decay, early stopping) per contenere il rischio di overfitting.

I risultati di questo lavoro devono quindi essere interpretati come **proof-of-concept metodologico** piuttosto che come evidenza definitiva di superiorità operativa degli LSTM. Le performance ottenute, pur promettenti, potrebbero riflettere overfitting su un campione limitato o sfruttamento di pattern specifici non generalizzabili. Applicazioni industriali richiederebbero espansione significativa su tre dimensioni: (i) universo investibile (2000+ bond), (ii) set di feature (30-50 fattori), (iii) granularità temporale.

Le performance riportate sono inoltre gross (upper bound teorico): costi realistici ridurrebbero sensibilmente lo Sharpe ratio in fase di implementazione. Tuttavia, il periodo di test esteso di 54 mesi (gennaio 2021 - settembre 2025) che include molteplici regimi di mercato fornisce evidenza più robusta rispetto a molti studi in letteratura. Nonostante questi caveat significativi, l'approccio dimostra merito scientifico come punto di partenza per ricerche future su scala maggiore.

10.2 Prospettive Future

Sviluppi futuri potrebbero affrontare le limitazioni identificate lungo tre direzioni:

Arricchimento Dataset

- **Estensione dell'universo investibile:** Espandere ad almeno 2000 obbligazioni mediante fonti dati più complete (Bloomberg, Refinitiv), raggiungendo copertura rappresentativa del mercato europeo.
- **Completare i prospetti cedolari:** Raccogliere i prospetti cedolari effettivamente realizzati, al fine di ottenere una rappresentazione più verosimile del universo investibile reale.
- **Rating creditizi storici:** Integrare serie temporali complete di rating creditizi storici per issuer ed emissioni per costruire un fattore Quality robusto.
- **Volumi e spread bid-ask:** Acquisire dati di trading per stimare liquidità e costi di transazione realisticamente.
- **Outstanding amount:** Ponderare posizioni per size emissione anziché equal-weight.
- **Espansione features:** Con dataset più ampio, includere fattori aggiuntivi (size emittente/emissione, sector momentum, CDS spreads).

Estensioni Metodologiche

- **Backtesting con frizioni:** Implementare simulatore che includa bid-ask spread stimati, ritardi esecuzione stocastici, e borrowing costs calibrati su letteratura.
- **Strategie long-only:** Sviluppare varianti che evitano short selling, usando sovrappesi/sottopesi rispetto a benchmark per implementabilità istituzionale.
- **Ensemble models:** Combinare LSTM con tree-based models (XGBoost, LightGBM) per robustezza predittiva.
- **Regime-conditional models:** Addestrare modelli separati per regimi di stress vs. normali, riconoscendo che driver predittivi possono variare.

10.3 Riproducibilità e Materiali Supplementari

Per garantire trasparenza e riproducibilità, tutti i materiali relativi a questa ricerca sono disponibili pubblicamente:

- **Repository completo:** Dataset processati, notebook Jupyter con codice di training e backtesting, file di configurazione del modello, e output sperimentali sono accessibili via Google Drive: [clicca qui per aprire](#)
- **Contenuti:** Il repository include:
 - `df_builder_v3.ipynb`: Pipeline di costruzione dataset (da dati grezzi Cbonds/WRDS a dataset finale 710 bond)
 - `lstm.ipynb`: Implementazione completa del modello LSTM, training, e backtesting strategia Long-Short
 - `df_main_with_factors.pkl`: Dataset finale usato per input lstm, in formato PKL, python friendly (features, target, metadati bond)
 - `lstm_output/`: Pesi del modello addestrato e log di training

10.4 Conclusione Finale

Questa tesi dimostra che reti neurali ricorrenti applicate al mercato dei Corporate Bond europei rappresentano un valido strumento di analisi e previsione delle performance anche per il mercato obbligazionario. I risultati supportano l'ipotesi che relazioni non-lineari e dipendenze temporali nei dati di credito contengono informazioni predittive non sfruttate da modelli lineari tradizionali.

Tuttavia, la traduzione da backtest teorico a strategia implementabile richiede investimenti sostanziali in infrastruttura dati (rating storici, volumi, bid-ask), capacità esecutive (accesso a liquidità OTC), e gestione del rischio (stress testing, regime conditioning).

Bibliografia

- [1] S. Gu, B. Kelly e D. Xiu, “Empirical Asset Pricing via Machine Learning,” *Review of Financial Studies*, vol. 33, n. 5, pp. 2223–2273, 2020.
- [2] M. A. Goldstein e E. S. Hotchkiss, “Providing Liquidity in an Illiquid Market: Dealer Behavior in US Corporate Bonds,” *Journal of Financial Economics*, vol. 135, n. 1, pp. 16–40, 2020.
- [3] European Central Bank. “Euro Area Yield Curves,” visitato il giorno 1 dic. 2024. indirizzo: https://www.ecb.europa.eu/stats/financial_markets_and_interest_rates/euro_area_yield_curves/html/index.en.html
- [4] E. F. Fama e K. R. French, “The Cross-Section of Expected Stock Returns,” *The Journal of Finance*, vol. 47, n. 2, pp. 427–465, 1992.
- [5] E. F. Fama e K. R. French, “Common Risk Factors in the Returns on Stocks and Bonds,” *Journal of Financial Economics*, vol. 33, n. 1, pp. 3–56, 1993.
- [6] P. Houweling e J. Van Zundert, “Factor Investing in the Corporate Bond Market,” *Financial Analysts Journal*, vol. 73, n. 2, pp. 100–115, 2017.
- [7] R. Israel, D. Palhares e S. Richardson, “Common Factors in Corporate Bond Returns,” *Journal of Investment Management*, vol. 16, n. 2, pp. 17–46, 2018.
- [8] A. Dickerson, Y. Nozawa e C. Robotti, “Factor Investing with Delays,” *Working Paper, SSRN*, 2024, Open Source Bond Asset Pricing (OSBAP).
- [9] A. Frazzini e L. H. Pedersen, “Betting Against Beta,” *Journal of Financial Economics*, vol. 111, n. 1, pp. 1–25, 2014.
- [10] S. Hochreiter e J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, n. 8, pp. 1735–1780, 1997.
- [11] Y. Bengio, P. Simard e P. Frasconi, “Learning Long-Term Dependencies with Gradient Descent is Difficult,” *IEEE Transactions on Neural Networks*, vol. 5, n. 2, pp. 157–166, 1994.
- [12] I. Goodfellow, Y. Bengio e A. Courville, *Deep Learning*. MIT Press, 2016.
- [13] D. P. Kingma e J. Ba, “Adam: A Method for Stochastic Optimization,” in *International Conference on Learning Representations (ICLR)*, 2015.
- [14] R. C. Grinold e R. N. Kahn, *Active Portfolio Management*. McGraw-Hill, 1999.
- [15] W. F. Sharpe, “Mutual Fund Performance,” *The Journal of Business*, vol. 39, n. 1, pp. 119–138, 1966.
- [16] Forbes Finance Council. “Hedge Fund Sharpe Ratio Benchmarks.” Average hedge fund Sharpe ratio 0.86; top-50 funds 1.75 (2017-2021), visitato il giorno 30 ago. 2022. indirizzo: <https://www.forbes.com/sites/jacobwolinsky/2022/08/30/heres-how-the-top-50-hedge-funds-generate-consistent-returns/>
- [17] T. I. Jensen, B. Kelly e L. H. Pedersen, “Is There a Replication Crisis in Finance?” *Journal of Finance*, vol. forthcoming, 2022.

- [18] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever e R. Salakhutdinov, “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” *Journal of Machine Learning Research*, vol. 15, n. 1, pp. 1929–1958, 2014.
- [19] P. Domingos, “The Role of Occam’s Razor in Knowledge Discovery,” *Data Mining and Knowledge Discovery*, vol. 3, pp. 409–425, 1999.
- [20] Cbonds. “Cbonds - Bond Information Platform,” visitato il giorno 1 dic. 2024. indirizzo: <https://cbonds.com/>
- [21] Wharton Research Data Services. “Compustat Global Database,” visitato il giorno 1 dic. 2024. indirizzo: <https://wrds-www.wharton.upenn.edu/pages/get-data/compustat-capital-iq-standard-poors/compustat/global-daily/>
- [22] A. Dickerson, Y. Nozawa e C. Robotti. “Open Source Bond Asset Pricing,” visitato il giorno 1 dic. 2024. indirizzo: <https://openbondassetpricing.com/>
- [23] A. Ben Dor, L. Dynkin, J. Hyman, P. Houweling e B. van Liebergen, “Duration Times Spread,” *Journal of Portfolio Management*, vol. 33, n. 2, pp. 77–100, 2007.
- [24] C. R. Harvey, Y. Liu e H. Zhu, “...and the Cross-Section of Expected Returns,” *Review of Financial Studies*, vol. 29, n. 1, pp. 5–68, 2016.
- [25] E. I. Altman, “Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy,” *The Journal of Finance*, vol. 23, n. 4, pp. 589–609, 1968.
- [26] J. Y. Campbell, J. Hilscher e J. Szilagyi, “In Search of Distress Risk,” *The Journal of Finance*, vol. 63, n. 6, pp. 2899–2939, 2008.
- [27] G. Feng et al., “Predicting Individual Corporate Bond Returns,” *Working Paper*, 2025.
- [28] Y. Bengio, “Practical Recommendations for Gradient-Based Training of Deep Architectures,” arXiv preprint arXiv:1206.5533, rapp. tecn., 2012.
- [29] W. F. Sharpe, “The Sharpe Ratio,” *Journal of Portfolio Management*, vol. 21, n. 1, pp. 49–58, 1994.
- [30] M. O’Hara, Y. Wang e X. Zhou, “Bid–Ask Spreads and the Pricing of Securitizations: 144a vs. Registered Securitizations,” *Journal of Financial Intermediation*, vol. 34, pp. 49–63, 2018.
- [31] A. Dickerson, C. Julliard e P. Mueller, “The Co-Pricing Factor Zoo,” *Working Paper*, SSRN 4589786, 2023.
- [32] CFA Institute, *CFA Program Curriculum Level III, Volume 3: Fixed Income*. Kaplan Schweser, 2022, SchweserNotes.
- [33] E. F. Fama e K. R. French, “A Five-Factor Asset Pricing Model,” *Journal of Financial Economics*, vol. 116, n. 1, pp. 1–22, 2015.
- [34] N. Jegadeesh e S. Titman, “Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency,” *The Journal of Finance*, vol. 48, n. 1, pp. 65–91, 1993.
- [35] J. Dick-Nielsen, P. Feldhütter e D. Lando, “Corporate Bond Liquidity Before and After the Onset of the Subprime Crisis,” *Journal of Financial Economics*, vol. 103, n. 3, pp. 471–492, 2012.
- [36] TensorFlow Team. “Time Series Forecasting with LSTM,” visitato il giorno 1 dic. 2024. indirizzo: https://www.tensorflow.org/tutorials/structured_data/time_series

- [37] Keras Team. “Keras LSTM Layer API Documentation,” visitato il giorno 6 gen. 2026. indirizzo: https://keras.io/api/layers/recurrent_layers/lstm/
- [38] Keras Team. “Keras Loss Functions API - Binary Crossentropy,” visitato il giorno 6 gen. 2026. indirizzo: https://keras.io/api/losses/probabilistic_losses/#binarycrossentropy-class
- [39] Keras Team. “Keras Classification Metrics API,” visitato il giorno 6 gen. 2026. indirizzo: https://keras.io/api/metrics/classification_metrics/

Innanzitutto, ringrazio il Prof. Sergio Guido Trezzi per la grande fiducia riposta in me, quindi per avermi dato la possibilità sin da subito di collaborare con dei professionisti del settore nello specifico campo da me richiesto, ma soprattutto ringrazio per l'incredibile comprensione e spinta data con ogni sua parola durante ogni fase di questo percorso.

Ringrazio Francesco e Pierfrancesco - i mentori di questo lavoro - per l'occasione di lavorare su temi così attuali, ambiziosi e stimolanti, per la disponibilità dimostrata in ogni nostro incontro e per avermi sempre guidato con onestà e trasparenza. Raccolgo da questo percorso delle competenze e delle esperienze che ritengo di estremo valore per il mio futuro professionale e personale.

Un grazie speciale ai miei genitori, mamma e papà, per tutti i sacrifici fatti per permettermi di frequentare questo ateneo, per non farmi mancare mai nulla di ciò che mi è servito fino ad oggi, per il sostegno e l'impegno che mettete per sostenermi; vi assicuro che ogni momento passato qui è stato prezioso e sfruttato come meglio ho potuto fare.

Mati, grazie per avermi sopportato parlare di questa tesi per mesi, grazie per avermi supportato incondizionatamente in ogni momento del mio percorso di studi e per avermi sempre dato conforto e forza per ripartire nei momenti di panico e difficoltà.

Grazie a Salvo, a Gio e Quero per avermi accompagnato in questa triennale; mi piace poter dire che questo traguardo l'ho raggiunto anche grazie a voi e a tutti i confronti, i consigli, le dispense e i momenti studio passati insieme. Spero tanto di non perdervi e poter condividere con voi anche tutte le esperienze che mi aspetteranno in futuro.

Grazie ai ragazzi di JeCatt che hanno completato e potenziato questo percorso, grazie per tutte le formazioni che l'università non mi ha dato, anche quelle che ritenevo poco utili, grazie a tutte le persone che grazie a JeCatt ho conosciuto, grazie per tutti quei discorsi che hanno acceso in me sempre più ambizione per la mia carriera.

Ringrazio tutta la mia famiglia, dai più vicini ai più lontani, per avermi sempre messo di loro spontanea volontà nelle migliori condizioni che potessi avere per raggiungere questo traguardo; nulla di tutto quello che avete sempre fatto per me è stato ignorato, grazie di tutto.

Meritano un ringraziamento anche tutti gli amici di Bareggio e dintorni che quando avevo bisogno di un momento per staccare ci sono sempre stati, grazie per avermi fatto tornare a casa più sereno di come sono arrivato.

Menzione d'onore per Claudio e Gianpietro, senza i quali non sarei mai riuscito a raggiungere anche gli obiettivi più ambiziosi - grazie per la vostra competenza e la quasi instancabile voglia di aiutarmi.